Machine Translated by Google

学习精细的双手操作
低成本硬件

托尼·赵[1]维卡什·库马尔[3]谢尔盖·莱文[2]切尔西·芬[1]
[1] 斯坦福大学 [2] 加州大学伯克利分校 [3] 元

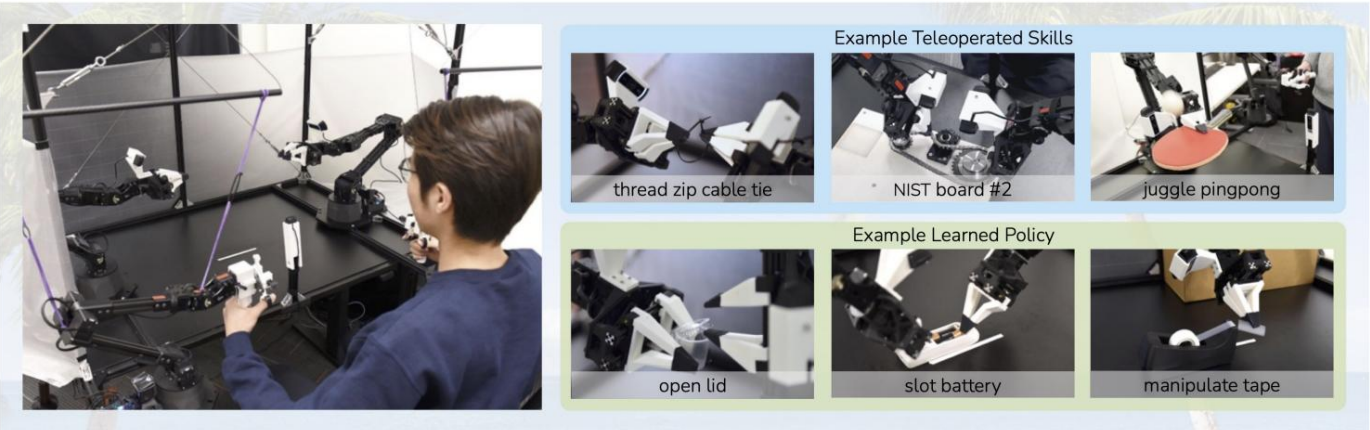

图 1： ALOHA:一款低成本的开源双手动远程操作硬件系统。该系统采用现成机器人和 3D 打印组件,总成本低于 2 万美元。左图:用户通过反向驱动引导机器人进行远程操作,跟随机器人则镜像执行相应的运动。
右图:ALOHA能够执行精准、互动性强且动态的任务。我们展示了远程操作技能和学习技能的示例。

摘要 精细操作任务,例如穿扎带或安装电池,对机器人而言历来难度极大,因为这些任务需要精准的操控、对接触力的精细协调以及闭环视觉反馈。执行这些任务通常需要高端机器人、高精度传感器或精细的校准,而这些设备成本高昂且设置复杂。学习能否使低成本、低精度的硬件也能执行这些精细操作任务?我们提出了一种低成本系统,该系统能够直接从通过定制远程操作界面收集的真实演示中执行端到端的模仿学习。然而,模仿学习本身也面临诸多挑战,尤其是在高精度领域:策略误差会随时间累积,而且人类的演示动作可能并非平稳。为了应对这些挑战,我们开发了一种简单而新颖的算法 基于Transformer的动作分块（ACT）,该算法能够学习动作序列的生成模型。ACT 使机器人能够在现实世界中学习 6 项高难度任务,例如打开半透明调味杯和安装电池,成功率高达 80-90%,而演示时间仅需 10 分钟。项目网站:tonyzhaozh.github.io/aloha

arXiv:2304.13705v1

一、引言

精细操作任务涉及精确的闭环反馈,需要高度的手眼协调能力,以便根据环境变化进行调整和重新计划。

这类操作任务的例子包括打开调味杯盖或安装电池,它们涉及精细的操作,例如捏、撬、撕,而不是像抓取和放置那样的大幅度动作。以图 1 中打开调味杯盖为例,杯子初始状态竖直放置在桌面上:右侧机械臂需要先将其倾斜,然后轻轻地将其推入已打开的左侧机械臂中。之后,左侧机械臂轻轻地闭合,将杯子提起。将杯子从桌子上拿下来。接下来,右手的一根手指从下方伸向杯子,撬开盖子。每一步都需要极高的精准度、精细的手眼协调能力和充分的接触。哪怕毫米级的误差都会导致任务失败。

现有的精细操作系统使用昂贵的机器人和高端传感器进行精确的状态估计[29, 60, 32, 41]。本文旨在开发一种低成本的精细操作系统,该系统相比之下更易于使用且可重复。

然而,低成本硬件的精度必然低于高端平台,这使得感知和规划方面的挑战更加突出。一个很有前景的解决方案是将学习机制融入系统。人类也不具备工业级的本体感觉[71],但我们仍然能够通过学习闭环视觉反馈并主动补偿误差来执行精细的任务。因此,在我们的系统中,我们训练了一个端到端的策略,该策略能够将来自普通网络摄像头的RGB图像直接映射到相应的动作。

这种像素到动作的建模方法特别适用于精细操作,因为精细操作通常涉及具有复杂物理特性的物体,学习操作策略远比对整个环境建模简单得多。以调味杯为例:对轻推杯子时的接触以及撬开杯盖时的形变进行建模,涉及大量自由度的复杂物理过程。设计一个足够精确以进行规划的模型需要大量的研究和针对特定任务的工程工作。相比之下,轻推和打开杯子的策略则简单得多,因为闭环策略可以根据杯子和杯盖的不同位置做出反应,而无需预先精确预测它们的运动方式。

Machine Translated by Google

然而,训练一个端到端的策略也面临着自身的挑战。策略的性能很大程度上取决于训练数据的分布,尤其是在精细操作的情况下,高质量的人类演示能够让系统学习人类的灵巧性,从而带来巨大的价值。因此,我们构建了一个低成本且灵巧的远程操作系统用于数据采集,并提出了一种能够有效学习演示数据的新型模仿学习算法。以下两段将概述各个组成部分。

远程操作系统。我们设计了一种远程操作系统,使用两组低成本的现成机械臂。这两组机械臂大致按比例缩小,我们采用关节空间映射进行远程操控。为了便于反向驱动,我们用3D打印组件增强了该系统,最终在2万美元的预算内打造出一个功能强大的远程操作系统。图1展示了该系统的功能,包括远程操控诸如穿扎带之类的精确任务、诸如抛接乒乓球之类的动态任务,以及诸如组装NIST板#2 [4]中的链条之类的需要大量接触的任务。

模仿学习算法。即使有高质量的示范,需要精确度和视觉反馈的任务对模仿学习来说也是一个巨大的挑战。预测动作中的微小误差会导致状态的巨大差异,从而加剧模仿学习中的“累积误差”问题[47, 64, 29]。为了解决这个问题,我们借鉴了动作组块的概念。动作组块是心理学中的一个概念,它描述了如何将一系列动作组合成一个组块,并作为一个整体执行[35]。在我们的算法中,策略预测接下来k个时间步的目标关节位置,而不是每次只预测一个时间步。这使得任务的有效时间范围缩小了k倍,从而减轻了累积误差。预测动作序列还有助于解决时间相关的混杂因素[61],例如示范中的停顿,这些停顿很难用马尔可夫单步策略建模。为了进一步提高策略的平滑性,我们提出了时间集成方法,该方法更频繁地查询策略并对重叠的动作组块进行平均。我们使用专为序列建模而设计的架构Transformer [65]来实现动作分块策略,并将其训练为条件变分自编码器（CVAE） [55, 33] ,以捕捉人类数据的变异性。我们将该方法命名为基于Transformer的动作分块（ACT） ,并发现它在一系列模拟和真实世界的精细操作任务中显著优于以往的模仿学习算法。

本文的主要贡献在于提出了一种低成本的精细操作学习系统,该系统由远程操作系统和一种新型模仿学习算法组成。尽管成本低廉,该远程操作系统仍能实现高精度、高交互性的任务。模仿学习算法 基于Transformer的动作分块（ACT） 能够学习精确的闭环行为,其性能显著优于以往的方法。这两个部分的协同作用使得系统能够在现实世界中直接学习6种精细操作技能,例如打开透明调味杯和安装电池,成功率高达80-90%,而学习过程仅需10分钟或50条演示轨迹。

二、相关工作

模仿学习在机器人操作中的应用。模仿学习使机器人能够直接向专家学习。行为克隆（BC） [44]是最简单的模仿学习算法之一,它将模仿视为从观察到动作的监督学习。许多研究致力于改进 BC,例如将历史信息融入各种架构[39, 49, 26, 7]、使用不同的训练目标[17, 42] 以及引入正则化[46]。其他研究则强调模仿学习的多任务或少样本特性[14, 25, 11],利用语言[51, 52, 26, 7] 或利用特定的任务结构[43, 68, 28, 52]。利用更多数据扩展这些模仿学习算法,已经构建出令人印象深刻的系统,这些系统能够泛化到新的物体、指令或场景[15, 26, 7, 32]。本文致力于构建一个低成本且能够执行精细操作任务的模仿学习系统。我们从硬件和软件两个层面着手解决这个问题,构建了一个高性能的远程操作系统,并提出了一种新型的模仿学习算法,该算法在精细操作任务上显著提升了现有方法的性能。

解决累积误差问题。边界条件（BC)的一个主要缺陷是累积误差,即先前时间步的误差会累积,导致机器人偏离其训练分布,从而产生难以恢复的状态[47, 64]。这个问题在精细操作场景中尤为突出[29]。缓解累积误差的一种方法是允许额外的策略内交互和专家校正,例如DAgger [47]及其变体[30, 40, 24]。然而,专家标注对于远程操作界面来说可能既耗时又不自然[29]。也可以在演示数据采集时注入噪声以获得具有校正行为的数据集[36],但对于精细操作而言,这种噪声注入可能直接导致任务失败,降低远程操作系统的灵巧性。为了规避这些问题,以往的研究工作以离线方式生成合成校正数据[16, 29, 70]。然而,这些方法仅限于低维状态可用或特定类型的任务（例如抓取）。鉴于这些局限性,我们需要从另一个角度解决累积误差问题,使其与高维视觉观测相兼容。我们提出通过动作分块来缩小任务的有效范围,即预测一个动作序列而非单个动作,然后对重叠的动作分块进行集成,从而生成既准确又平滑的轨迹。

双侧操作。双侧操作在机器人领域有着悠久的历史,并随着硬件成本的降低而日益普及。早期的研究从经典控制的角度出发,利用已知的环境动力学来处理双侧操作[54, 48],但设计此类模型可能耗时较长,并且对于具有复杂物理特性的物体可能不够精确。近年来,学习方法已被应用于双侧操作系统中,例如强化学习[9, 10]、模仿人类演示[34, 37, 59, 67, 32]或学习预测串联的关键点。

Machine Translated by Google

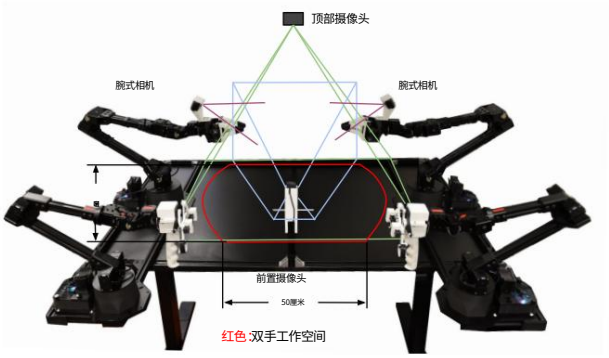

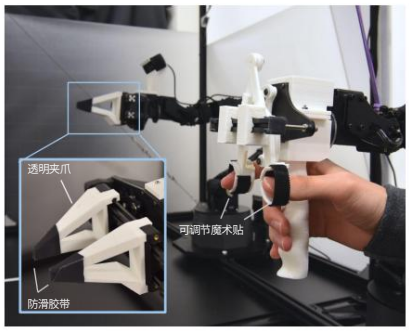

ViperX 6自由度机械臂（从动臂）

#Dofs	6+夹持器
抵达	750毫米
跨度	1500毫米
重复性	1毫米
准确性	5-8毫米
工作有效载荷	750克

图 3:左图:前部、顶部和两个手腕摄像头的相机视角,以及 ALOHA 的双手工作空间示意图。
中间: “手柄和剪刀”机构和定制夹爪的细节图。右图:ViperX 6dof 机器人的技术规格 [1]。

运动基元[20, 19, 50]。一些研究还专注于精细操作任务,例如解开绳结、展平布料,甚至穿针引线[19, 18, 31],但这些研究使用的是价格昂贵的机器人,例如达芬奇手术机器人或ABB YuMi。我们的研究转向低成本硬件,例如每个售价约5000美元的机械臂,并力求使其能够执行高精度闭环任务。我们的远程操作设置与Kim等人[32]的设置最为相似,后者也使用了引导机器人和跟随机器人之间的关节空间映射。与之前的系统不同,我们没有使用特殊的编码器、传感器或加工部件。我们的系统仅使用现成的机器人和少量3D打印部件构建,使得非专业人员能够在不到2小时内完成组装。

三、ALOHA:用于双手动远程操作的低成本开源硬件系统

我们致力于开发一种易于使用且高性能的精细操作远程操作系统。我们将设计考虑因素总结为以下5个原则。

1)低成本:整个系统对于大多数机器人实验室来说应该在预算范围内,与单个工业机械臂相当。
2)用途广泛:可应用于对现实世界物体进行各种精细操作的任务。

3)用户友好:系统应该直观、可靠、易于使用。

4)可修复性:当该装置不可避免地发生故障时,研究人员可以轻松修复该装置。
5)易于组装:研究人员可以快速组装,采用易于获取的材料。

在选择机器人时,原则 1、4 和 5 促使我们构建了一个由两个ViperX 六自由度机械臂[1, 66] 组成的双手动平行爪夹持装置。出于成本和维护方面的考虑,我们没有采用灵巧的机械手。所使用的 ViperX 机械臂的有效载荷为 750 克,跨度为 1.5 米,精度为 5-8 毫米。该机器人采用模块化设计,易于维修:如果电机发生故障,可以轻松更换低成本的 Dynamixel 电机。该机器人可以以大约 5600 美元的价格购买。然而,原装机械手的灵活性不足以完成精细操作任务。因此,我们设计了自己的 3D 打印“透明”机械手,并贴上抓握胶带（图 3）。这提供了良好的可视性。

在进行精细操作时,即使使用薄塑料薄膜也能牢固抓握。

接下来,我们致力于围绕ViperX机器人设计一个用户友好性极高的远程操作系统。我们没有采用传统的任务空间映射方式,而是直接利用同一公司生产的小型机器人WidowX（售价3300美元)进行关节空间映射[2]。用户通过反向驱动小型WidowX（“领导者”）进行远程操作,WidowX的关节与较大的ViperX（“跟随者”)同步运动。在开发这套系统的过程中,我们注意到与任务空间映射相比,使用关节空间映射具有以下几个优势:(1)精细操作通常需要在机器人的奇异点附近进行,而我们的机器人具有6个自由度且没有冗余。在这种情况下,现成的逆运动学(IK)算法经常失效。而关节空间映射则能够保证在关节活动范围内实现高带宽控制,同时还能减少计算量并降低延迟。 (2)领头机器人的重量可以防止用户移动过快,还可以抑制轻微的振动。

我们注意到,在进行精确任务时,采用关节空间映射比手持VR控制器能获得更好的性能。为了进一步提升远程操作体验,我们设计了一种可改装到主控机器人上的3D打印“手柄剪刀”机构（图3）。该机构降低了操作员反向驱动电机所需的力,并允许对夹爪进行连续控制,而非简单的开合动作。

我们还设计了一种橡皮筋负载平衡装置,可以部分抵消操控者一侧的重力。这可以减轻操作者所需的体力,并使更长时间的远程操作（例如超过30分钟)成为可能。项目网站上提供了更多关于该装置的详细信息。

其余装置包括一个由20×20mm铝型材制成的机器人笼,并用交叉钢索加固。总共有四个罗技C922x网络摄像头,每个摄像头传输480×640 RGB图像。其中两个摄像头安装在跟随机器人的腕部,可以近距离观察机械臂。其余两个摄像头分别安装在机器人的正面和顶部（图3）。远程操作和数据记录的频率均为50Hz。

基于上述设计考虑,我们在 2 万美元的预算内构建了 ALOHA 双手动遥控系统,并进行了比较。

Machine Translated by Google

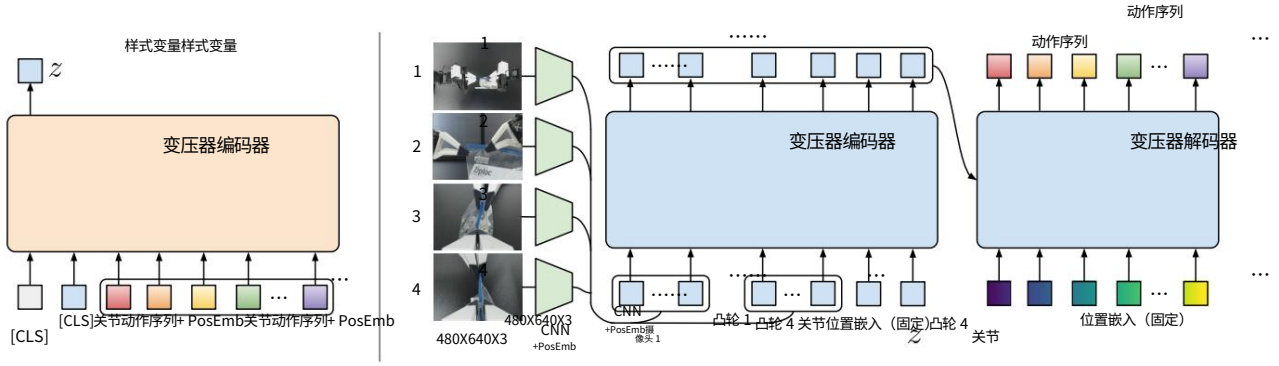

图 4:基于 Transformer 的动作分块算法 (ACT) 架构。我们将 ACT 训练为条件变分自编码器 (CVAE),它包含一个编码器和一个解码器。左图:CVAE 的编码器将动作序列和关节观测值压缩成风格变量 z。在测试阶段,编码器会被丢弃。右图:ACT 的解码器或策略使用 Transformer编码器合成来自多个视角、关节位置和z 的图像,并使用 Transformer 解码器预测动作序列。在测试阶段,z 被简单地设置为先验均值（即零）。

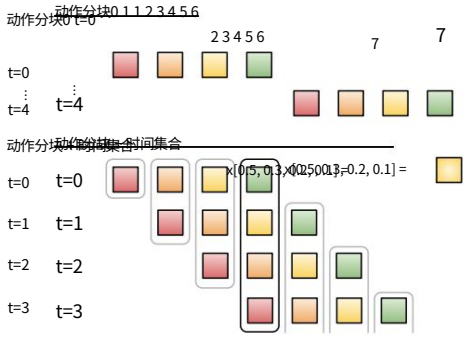

图 5:我们在应用动作时同时采用动作分块和时间集成,而不是交错观察和执行。

归属于单个研究部门,例如 Franka Emika Panda。

ALOHA 可实现以下远程操作： ·精确任务,例如穿扎带、从钱包中取出信用卡以及打开或关闭自封袋。 ·需要大量接触的任务,例如将 288 针 RAM 插入计算机主板、翻书页以及组装 NIST 2 号板 [4] 中的链条和皮带。 ·动态任务,例如用真正的乒乓球拍抛接乒乓球、保持乒乓球平衡而不使其掉落以及在空中挥动打开的塑料袋。

据我们所知,诸如穿扎带、插入内存条和抛接乒乓球等技能,即使是预算高出 5-10 倍的现有远程操作系统也无法实现[21, 5]。附录 A 中提供了更详细的价格和功能对比,图 9 则展示了 ALOHA 的更多功能。

为了让 ALOHA 更易于使用,我们开源了所有软件和硬件,并提供了详细的教程,涵盖 3D 打印、框架组装和软件安装等各个方面。您可以在项目网站上找到该教程。

IV.变形金刚动作大片

正如我们将在第五节中看到的,现有的模仿学习算法在需要高频控制和闭环反馈的细粒度任务上表现不佳。因此,我们开发了一种新的算法基于Transformer的动作分块（ACT）,以充分利用ALOHA收集的数据。我们首先概述ACT的训练流程,然后深入探讨每一项设计选择。

为了训练 ACT 完成一项新任务,我们首先使用 ALOHA 收集人类操作演示数据。我们记录领头机器人的关节位置（即来自人类操作员的输入）,并将其用作动作。使用领头机器人的关节位置而非跟随机器人的关节位置至关重要,因为施加的力的大小是通过底层 PID 控制器隐式地由两者之差决定的。观测数据包括跟随机器人的当前关节位置以及来自 4 个摄像头的图像流。接下来,我们训练 ACT根据当前观测数据预测未来的动作序列。这里的一个动作对应于下一个时间步中双臂的目标关节位置。直观地说,ACT 试图根据当前观测数据模仿人类操作员在接下来的时间步中会执行的操作。这些目标关节位置随后由Dynamixel 电机内部的底层高频 PID 控制器进行跟踪。在测试阶段,我们加载验证损失最低的策略,并将其部署到实际环境中。主要挑战在于误差的累积,即先前动作产生的误差会导致状态超出训练分布范围。

A. 动作组块和时间集合

为了应对模仿学习中累积误差的问题,并使其与像素到动作策略（图 II)兼容,我们试图减少高频采集的长轨迹的有效范围。我们借鉴了动作组块的概念,这是一种神经科学概念,它将单个动作分组并作为一个单元执行,从而提高存储和执行效率[35]。直观地说,一组动作可以对应于抓住糖纸的一角或将电池插入插槽。在我们的实现中,我们将组块大小固定为k:每隔k步,智能体接收一个观测值,生成接下来的k 个动作,并按顺序执行这些动作（图 5）。这意味着任务的有效范围减少了 k 倍。具体来说,该策略建模的是πθ(at:t+k|st)而不是πθ(at|st)。组块还可以帮助建模人类演示中的非马尔可夫行为。

具体而言,单步策略难以应对时间相关的混杂因素,例如示威活动中途的停顿[61],因为行为不仅取决于状态,还取决于时间步长。动作分块可以缓解这个问题。

Machine Translated by Google

算法 1 ACT 训练

1:给定:演示数据集 D,块大小 k,权重 β。
2:令at、 ot表示时间步t 的动作和观察， o¯t表示没有图像观察的ot 。

3:初始化编码器qφ(z|at:t+k, o¯t)
4:初始化解码器πθ(at:t+k|ot, z) 5:对于迭代n = 1, 2, ...执行6:从
D中采样ot, at:t+k 7:从qφ(z|at:t+k, o¯t)中采样z 8:

根据πθ(at:t+k|ot, z)预测a t:t+k
9: Lreconst = MSE(at:t+k, at:t+k)
10: Lreg = DKL(qφ(z|at:t+k, o¯t) N (0,I))
11:使用 ADAM 更新 θ、φ,L = Lreconst + βLreg

算法 2 ACT 推理

1:给定:训练后的πθ,回合长度 T,权重 m。
2:初始化 FIFO 缓冲区B[0 : T],其中B[t]存储预测的时间步 t 的动作。3 :对于时间步 t = 1, 2, ...T执行以下
操作
4: 预测a t:t+k,其中πθ(at:t+k|ot, z),z = 0
5:分别将a t:t+k添加到缓冲区 B[t : t + k] 中
6:获取当前步长动作At = B[t] wiAt[i]/ wi,其中wi
7:申请地点= = exp(−m i)

当混杂因素位于一个块内时,就会出现这个问题,而不会引入历史条件策略的因果混淆问题[12]。

动作分块的简单实现可能并非最优:每隔k步突然引入一个新的环境观察结果,这可能导致机器人运动不流畅。

为了提高平滑性并避免执行和观察之间的离散切换,我们在每个时间步查询策略。

这使得不同的动作块相互重叠,并且在给定的时间步长内会有多个预测动作。我们在图 5 中对此进行了说明,并提出了一种时间集成方法来组合这些预测。我们的时间集成方法对这些预测进行加权平均,加权方案为wi = exp(−m i),其中w0是最早动作的权重。新观测值的整合速度由 m 控制， m越小,整合速度越快。我们注意到,与典型的平滑方法（将当前动作与相邻时间步长的动作聚合,从而导致偏差)不同,我们聚合的是同一时间步长预测的动作。此过程不会增加额外的训练成本,只会增加额外的推理时间计算。在实践中,我们发现动作块划分和时间集成对于 ACT 的成功都至关重要,ACT 能够产生精确且流畅的运动。我们在第六节 A 小节的消融实验中更详细地讨论了这些组成部分。

B. 人类数据建模

另一个挑战在于如何从充满噪声的人类演示中学习。面对同样的观察,人类可能会采用不同的轨迹来完成任务。此外,在精度要求较低的领域,人类的行为也更具随机性[38]。

因此,政策制定者必须重点关注那些对精度要求极高的地区。我们通过训练我们的模型来解决这个问题。

我们将动作分块策略作为生成模型。具体来说,我们训练该策略为条件变分自编码器（CVAE） [55],以生成基于当前观测值的动作序列。CVAE 由两个部分组成:CVAE 编码器和 CVAE 解码器,分别如图 4 左侧和右侧所示。CVAE 编码器仅用于训练CVAE 解码器（即策略）,在测试阶段会被丢弃。

具体来说,CVAE编码器以当前观测值和动作序列为输入,预测风格变量z分布的均值和方差,该分布参数化为对角高斯分布。为了加快实际训练速度,我们省略了图像观测值,仅以本体感受观测值和动作序列为条件。CVAE解码器（即策略)同时以z和当前观测值（图像+关节位置)为条件来预测动作序列。在测试阶段,我们将z设置为先验分布的均值,即零,以实现确定性解码。整个模型的训练目标是最大化演示动作片段的对数似然,即log πθ(at:t+k|st),其目标函数为标准的VAE minθ − st,at:t+k∈D,该目标函数包含两项:重构损失和一项将编码器正则化为高斯先验的项。参考[23],我们使用超参数β对第二项进行加权。直观地说， β值越高， z中传输的信息就越少[62]。

总体而言,我们发现 CVAE 目标对于从人类演示中学习精确任务至关重要。我们将在第六节 B 部分进行更详细的讨论。

C. ACT的实现我们使用

Transformer实现CVAE编码器和解码器,因为Transformer既可以用于合成序列信息,也可以用于生成新序列。CVAE编码器采用类似BERT的Transformer编码器[13]实现。编码器的输入是当前关节位置和来自演示数据集的长度为k的目标动作序列,并在其前面加上一个类似于BERT的学习得到的“[CLS]”标记。这构成了一个长度为k+2的输入（图4左）。

经过Transformer处理后,对应于“[CLS]”的特征用于预测“风格变量” z的均值和方差,然后将预测结果作为解码器的输入。CVAE解码器（即策略)以当前观测值和z作为输入,预测接下来的k个动作（图4右）。我们使用ResNet图像编码器、Transformer编码器和Transformer解码器来实现CVAE解码器。

直观地说,Transformer编码器综合了来自不同相机视角、关节位置和风格变量的信息,而Transformer解码器则生成一个连贯的动作序列。观测数据包括4张分辨率为480×640的RGB图像,以及两个机械臂的关节位置（总共7+7=14个自由度）。动作空间是两个机器人的绝对关节位置,一个14维向量。因此,通过动作分块,该策略在给定当前观测数据的情况下输出一个k×14的张量。该策略首先使用ResNet18骨干网络[22]处理图像,将480×640×3的RGB图像转换为15×20×512的特征图。然后,我们沿空间维度展平这些特征图,得到一个300×512的序列。

为了保留空间信息,我们添加了一个二维正弦波。

Machine Translated by Google

将位置嵌入映射到特征序列[8]。对所有4张图像重复此操作,得到一个1200×512维度的特征序列。然后,我们添加两个特征:当前关节位置和“风格变量” z。它们分别通过线性层从原始维度投影到512维度。因此,Transformer编码器的输入为1202×512。Transformer解码器通过交叉注意力机制对编码器的输出进行约束,其中输入序列是一个固定的k×512维度的位置嵌入,键和值来自编码器。这使得Transformer解码器的输出维度为k×512,然后使用多层感知器（MLP)将其下投影到k×14维度,对应于接下来k步的预测目标关节位置。我们使用L1损失而不是更常用的L2损失进行重建:我们注意到L1损失可以更精确地建模动作序列。我们还注意到,当使用增量关节位置而不是目标关节位置作为动作时,性能会下降。我们在附录 C中包含了详细的架构图。

我们在算法 1 和算法 2 中总结了 ACT 的训练和推理过程。该模型拥有约 8000 万个参数,我们针对每个任务从头开始训练。在单块 11G RTX 2080 Ti GPU 上,训练大约需要 5 小时,而推理时间在同一台机器上约为 0.01 秒。

五、实验

我们通过实验评估了ACT在精细操作任务上的性能。为了便于复现,除了使用ALOHA完成6个真实世界任务外,我们还在MuJoCo [63]中构建了两个模拟的精细操作任务。每个任务的视频都已发布在项目网站上。

A. 任务

所有8项任务都需要精细的双手操作,如图6所示。对于“滑动拉链袋”任务,右手机械臂需要精确抓取拉链袋的滑块并将其打开,左手机械臂则固定住袋身。对于“电池插槽”任务,右手机械臂需要先将电池放入遥控器的电池插槽中,然后用指尖轻轻按压电池边缘,直至完全插入。由于电池插槽内的弹簧会导致遥控器在插入过程中向相反方向移动,因此左手机械臂需要向下按压遥控器以固定其位置。对于“打开杯子”任务,目标是打开一个小调味杯的盖子。由于杯子尺寸较小,机械臂无法仅从侧面抓取杯身。因此,我们需要同时使用两个机械臂:右手手指先轻轻敲击杯子边缘使其倾斜,然后将其推入打开的左手机械臂中。这一推入步骤需要极高的精度,并且需要与视觉感知形成闭环。左侧夹爪轻轻合拢,将杯子从桌面上提起,随后右手手指撬开杯盖,这一步也需要精准操作,以免扣错杯盖或损坏杯子。穿线魔术贴的目的是将魔术贴扎带的一端插入另一端的小环中。

左侧夹爪需要先从……上勾住魔术贴。

首先,右手机械臂抓取纸盒上的魔术贴,然后用右手机械臂在空中夹住纸盒的尾部。接着,两只机械臂协同工作,将魔术贴的一端插入纸盒的另一端。纸盒的环尺寸为3 毫米 x 25 毫米,而魔术贴的尺寸为 2 毫米 x 10-25 毫米（具体尺寸取决于位置）。为了成功完成这项任务,机器人必须利用视觉反馈来修正每次抓取时的偏差,因为即使第一次抓取时只有几毫米的误差,也会在第二次空中抓取时累积,导致插入阶段的偏差超过 10 毫米。对于预制胶带,目标是将一小段胶带挂在纸箱边缘。右手机械臂首先抓取胶带,并用胶带切割器的刀片将其切割,然后将胶带段在空中传递给左手机械臂。接下来,双臂靠近盒子,左臂轻轻地将胶带段放在盒子表面,右手手指向下按压胶带防止滑动,然后左臂张开夹爪松开胶带。与穿线魔术贴类似,这项任务需要双臂之间多个精细的协调操作。在“穿鞋”环节,目标是将鞋子穿到固定的人体模型脚上,并用鞋子的魔术贴带固定。

首先,机械臂需要分别抓住鞋舌和鞋领,将鞋子抬起并靠近脚部。由于鞋子很紧,穿鞋颇具挑战性:机械臂需要仔细协调,才能将脚轻轻推入鞋内,而且双臂的抓握力必须足够强劲,才能克服袜子和鞋子之间的摩擦力。然后,左臂绕到鞋底,托住鞋子防止其滑落,接着右臂翻转魔术贴并将其按压在鞋子上以固定。只有当双臂松开后鞋子仍然紧贴脚部时,任务才算成功。在模拟任务“搬运立方体”中,右臂需要先拿起放在桌上的红色立方体,然后将其放入左臂的机械臂中。由于立方体和左臂机械臂之间的间隙很小（约1厘米）,任何微小的误差都可能导致碰撞,从而造成任务失败。在模拟的双手插入任务中,左右臂需要分别拿起插座和插销,然后在空中插入,使插销接触到插座内的“销钉”。插入阶段的间隙约为5毫米。对于所有8个任务,物体的初始位置要么沿着15厘米的白色参考线随机变化（真实世界任务）,要么均匀分布在二维区域内（模拟任务）。我们在图6和图7中提供了初始位置和子任务的示意图。我们的评估还将报告每个子任务的性能。

除了完成这些任务所需的精细双手控制之外,我们使用的物体本身也带来了显著的感知挑战。例如,自封袋几乎是透明的,只有一条细细的蓝色封口线。袋子上的褶皱和里面反光的糖果包装纸在随机化过程中都会发生变化,从而分散感知系统的注意力。

其他透明或半透明物体包括胶带以及调味杯的盖子和杯身,这使得它们难以精确辨认,不适合深度相机拍摄。黑色桌面也与许多感兴趣的物体形成低对比度,例如黑色魔术贴扎带和黑色

Machine Translated by Google

实际任务定义

滑动拉链袋:打开竖立在桌面上的拉链袋。袋子沿15厘米长的白线随机放置。袋子从距离桌面约5厘米处落下,以随机变形,这会影响袋子的高度和外观。左臂首先抓住袋身（子任务1:抓取）,然后右臂捏住拉链（子任务2:捏住）。接着右臂向右移动拉开拉链（子任务3:打开）。

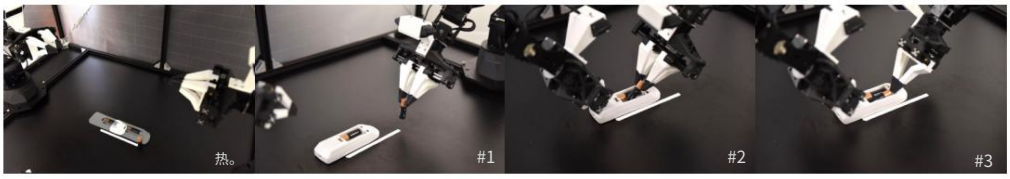

电池安装:将电池装入遥控器。遥控器沿15厘米长的白线随机放置。电池初始位置大致相同,但旋转角度可能不同。右臂首先抓取电池（子任务1:抓取）,然后将其放入电池槽（子任务2:放置）。左臂按住遥控器以防止其滑动,同时右臂将电池推入（子任务3:插入）。

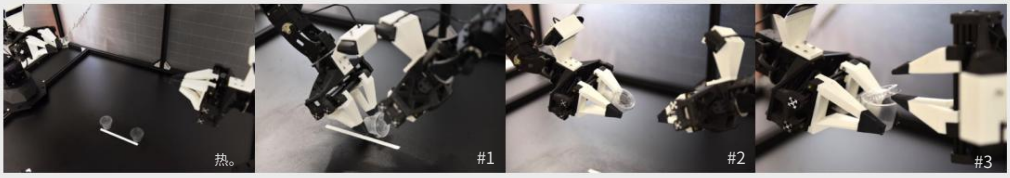

打开杯子:拿起并打开一个半透明调味杯的盖子。杯子随机放置在15厘米长的白线上。双臂靠近杯子,右手轻轻地将杯子倾斜（子任务1:倾斜）,并将其推入左手的夹爪中。然后,左手轻轻地合拢夹爪,将杯子从桌面上拿起（子任务2:抓取）。接下来,右手从下方靠近杯盖,撬开杯盖。

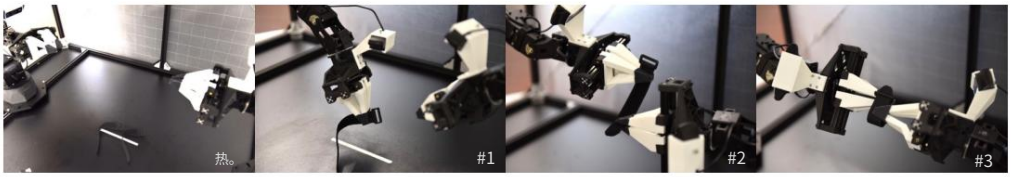

穿线魔术贴:拿起魔术贴扎带,将一端插入另一端的环中。魔术贴扎带沿15厘米长的白线随机分布。左臂首先捏住靠近塑料环的魔术贴扎带（子任务1:提起）。右臂在空中抓住魔术贴扎带的尾部（子任务2:抓取）。然后,双臂协调配合,将魔术贴扎带变形,并将其一端插入另一端的塑料环中。

准备胶带:在纸箱边缘挂上一小段胶带。胶带座沿15厘米白线随机放置。首先,右侧机械臂从侧面夹住胶带（子任务1:夹住）。然后,它提起胶带并拉开,接着用胶带座的刀片将其切断（子任务2:切割）。接下来,右侧机械臂将胶带段在空中传递给左侧机械臂（子任务3:传递）,同时两个机械臂向文具纸箱的角落移动。然后,左侧机械臂将胶带段平放在纸箱表面,同时右侧机械臂向下按压胶带以防止其滑动。最后,左侧机械臂打开机械臂,松开胶带（子任务4:悬挂）。

穿鞋:将一双魔术贴鞋穿在固定的人体模型脚上。鞋子的位置沿15厘米长的白线随机排列。首先,左右手同时抓取鞋子（子任务1:提起）。然后,双臂协调地将鞋子穿上,鞋跟贴合鞋后跟（子任务2:插入）。接下来,左臂移动以支撑鞋子（子任务3:支撑）,然后右臂固定魔术贴（子任务4:固定）。

图 6:实际任务定义。对于 6 个实际任务中的每一个,我们都展示了其初始化过程和子任务。

Machine Translated by Google

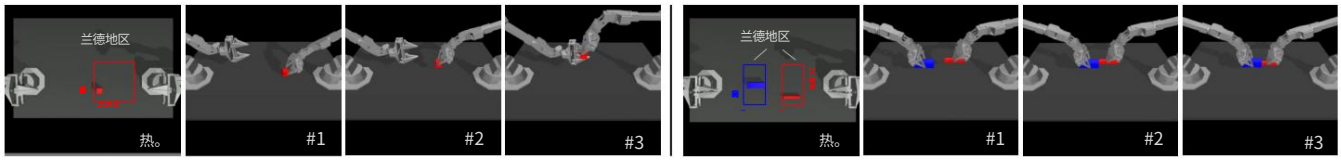

左图:立方体转移。将红色立方体转移到另一只手臂上。右臂触碰（#1)并抓取（#2)红色立方体,然后将其递给左臂。
右图:双手插入法。将红色插销插入蓝色插槽。双手握住（#1）,使插槽和插销接触（#2）,然后插入。

图 7:模拟任务定义。对于两个模拟任务中的每一个,我们都展示了它们的初始化过程和子任务。

	立方体传输（模拟）			双手插入（模拟）			滑动式 Ziploc （真实）			插槽电池（真实）		
	感动	升起	转移	抓牢	接触	插入	抓牢	捏	打开	抓牢	地方	插入
BC-ConvMLP 34 | 3		17 | 1	1 | 0	5 | 0	1 | 0	1 | 0	0	0	0	0	0	0
赌注	60 | 16	51 | 13	27 | 1	21 | 0	4 | 0	3 | 0	8	0	0	4	0	0
RT-1	44 | 4	33 | 2	2 | 0	2 | 0	0 | 0	1 | 0	4	0	0	4	0	0
来	13 | 17	9 | 11	3 | 0	6 | 0	1 | 0	1 | 0	28	0	0	20	0	0
ACT（我们的）	97 | 82	90 | 60	86 | 50	93 | 76 90 | 66		32 | 20	92	96	88	100	100	96

表一： 2 个模拟任务和 2 个真实任务的成功率（%）,并将我们的方法与 4 个基线方法进行比较。对于两个模拟任务,我们
报告[使用脚本数据进行训练 | 使用人工数据进行训练],每个样本包含3个种子,并进行50次策略评估。对于真实世界的任务,我们
报告显示,使用人类数据进行训练,采用 1 个种子点和 25 次评估。总体而言,ACT 的性能显著优于以往的方法。

	公开杯（真实）			线粘扣（真正的）			准备胶带（真实）				穿上鞋子（真实）			
	倾倒	抓住	打开盖子	提起	抓住	插入	抓住	切割	交接	悬挂	提起	插入	支撑	固定
赌注	12	0	0	24	0	0	8	0	0	0	12	0	0	0
ACT（我们的）	100	96	84	92	40	20	96	92	72	64	100	92	92	92

表二:其余3项实际任务的成功率（%）。我们仅与性能最佳的基准模型BeT进行比较。

胶带座。尤其是从顶部看,这很有挑战性。
由于突出面积较小,需要将魔术贴绑带固定在特定位置。

B. 数据收集

针对所有 6 项真实世界任务,我们使用以下方式收集演示：
ALOHA远程操作。每个回合耗时8-14秒。
由人工操作员根据复杂程度执行操作
任务,在控制条件下,相当于 400-700 个时间步。
频率为50Hz。我们对每个任务录制50次演示。
除了线粘扣带（有100个)之外,总数量为
因此,每次演示大约需要10-20分钟的数据。
任务完成时间,由于重置,实际耗时30-60分钟。
以及远程操作员的失误。对于这两个模拟任务,我们
收集两种类型的演示:一种是带有脚本的演示。
政策以及一项包含人类示范的政策。远程操作
在模拟中,我们使用ALOHA的“领导机器人”进行控制。
模拟机器人,操作员实时观察。
显示器上环境的渲染图。在这两种情况下,
我们记录了 50 次成功的演示。

我们强调,所有人类示威活动本质上都是
随机性,即使所有数据都由一个人收集
演示。以空中交接胶带为例。
以片段为例:交接的确切位置
每集都不一样。人类没有视觉或
通过触觉参考在同一位置执行操作。因此,
如果成功执行任务,该策略需要学习到：
两个夹爪在作业过程中绝不能相互碰撞。
交接时,左侧夹爪应始终移动到
采取能够抓住胶带的姿势,而不是试图记住位置。
具体交接地点可能因地而异
示威游行。

C. 实验结果

我们将 ACT 与四种先前的模仿学习方法进行了比较。
BC-ConvMLP是最简单但应用最广泛的基线方法[69, 26],它处理当前的图像观测值。
使用卷积神经网络,其输出特征是
结合关节位置来预测动作。
BeT [49]也采用了 Transformer 作为架构,但是
主要区别在于：(1)没有动作组块:该模型预测
（2)根据观察历史采取的行动;以及（2)图像
观测数据由单独训练的冻结算法进行预处理。
视觉编码器。即感知和控制网络。
它们并非联合优化。RT -1 [7]是另一种基于 Transformer 的架构,它根据固定长度的预测结果预测一个动作。
过往观测历史。BeT 和 RT-1 都进行了离散化处理。
动作空间:输出是一个类别分布。
离散的箱体,但在 BeT 的情况下,箱体中心会额外增加一个连续的偏移量。而我们的方法 ACT 则直接使用离散的箱体。
预测连续动作,以满足所需的精确度。
在精细操作方面。最后， VINN [42]是一种非参数方法。
该方法假定在测试时可以访问演示。
给定一个新的观测值,它会检索k 个观测值。
选择最相似的视觉特征,并返回一个使用该特征的操作。

Machine Translated by Google

加权k近邻算法。视觉特征提取器是一个预训练的ResNet模型,它使用无监督学习在演示数据上进行了微调。我们使用立方体迁移仔细调整了这四种先前方法的超参数。超参数的详细信息见附录D。

为了与以往方法进行详细比较,我们在表 I 中报告了两个模拟任务和两个真实任务的平均成功率。对于模拟任务,我们使用 3 个随机种子,每个种子进行 50 次试验,并取平均值。我们报告了脚本数据（分隔线左侧)和人工数据（分隔线右侧)的成功率。对于真实任务,我们运行一个种子,并进行 25 次试验进行评估。与所有以往方法相比,ACT 取得了最高的成功率,在每个任务上都大幅优于第二好的算法。对于使用脚本数据或人工数据的两个模拟任务,ACT 的成功率分别比之前最好的方法高出 59%、49%、29%和 20%。虽然以往的方法能够在前两个子任务中取得进展,但最终成功率仍然很低,低于 30%。对于两个真实任务“滑动拉链袋”和“插入电池” ,ACT 的最终成功率分别达到了 88% 和 96%,而其他方法在第一阶段之后就未能取得任何进展。我们认为先前方法性能不佳的原因在于数据中误差的累积和非马尔可夫行为:机器人行为在回合末期显著退化,并且在某些状态下会无限期暂停。ACT 通过动作分块来缓解这两个问题。我们在第六节 A部分进行的消融实验也表明,引入分块可以显著改进这些先前的方法。此外,我们注意到,在模拟任务中,当从脚本数据切换到人类数据时,所有方法的性能都会下降:人类演示的随机性和多模态性使得模仿学习变得更加困难。

我们在表二中报告了剩余3项实际任务的成功率。对于这些任务,我们仅与迄今为止任务成功率最高的BeT进行比较。我们的方法ACT在“打开杯子”任务中成功率达到84%,在“穿魔术贴”任务中成功率为20%,在“准备胶带”任务中成功率为64%,在“穿鞋”任务中成功率为92%,再次优于BeT,后者在这些具有挑战性的任务中最终成功率为零。我们观察到ACT在“穿魔术贴”任务中的成功率相对较低,成功率在每个阶段都下降了大约一半,从第一阶段的92%降至最终的20%。我们观察到的失败模式是:1)在第二阶段,右臂过早闭合夹爪,未能抓住空中扎带的尾部;2)在第三阶段,插入不够精确,未能抓住扎带的环。在这两种情况下,都很难从图像观察中确定扎带的确切位置:黑色扎带与背景之间的对比度很低,而且扎带仅占图像的一小部分。我们在附录 B 中提供了图像观察示例。

六、消融术

ACT采用动作分块和时间集成来减轻累积误差,并更好地处理非马尔可夫演示。它还将策略训练为条件变分自编码器（VAE） ,以对带噪声的人类演示进行建模。在本节中,我们对上述每个组成部分进行消融,并结合一项用户研究,强调了 ALOHA 中高频控制的必要性。

我们报告了在总共四种设置下的结果:两种模拟任务,分别采用脚本演示或人工演示。

A. 动作组块和时间集成

在VC小节中,我们观察到ACT的性能显著优于以往仅预测单步动作的方法,并假设动作分块是关键的设计选择。由于k决定了每个“块”中序列的长度,我们可以通过改变k值来分析这一假设。k =1对应于无动作分块,而k=episode_length对应于完全开环控制,此时机器人基于第一次观测输出整个episode的动作序列。在这些实验中,我们禁用了时间集成,仅测量分块的效果,并为每个k值训练了单独的策略。在图8(a)中,我们绘制了4种设置下的平均成功率,这些设置对应于使用人类数据或脚本数据的2个模拟任务,其中蓝线代表未使用时间集成的ACT。我们观察到,性能从k=1时的1%急剧提高到k=100时的44% ,然后随着k值的增加略有下降。这表明,更多的分块和更小的有效预测范围通常会提高性能。我们认为 k = 200 和 400 处（即接近开环控制)的轻微下降是由于缺乏反应行为以及难以对长动作序列进行建模所致。为了进一步评估动作分块的有效性和通用性,我们利用动作分块增强了两种基线方法。对于 BC-ConvMLP,我们简单地将输出维度增加到k action_dim;对于 VINN,我们提取接下来的k 个动作。我们在图 8 (a) 中可视化了它们在不同 k 值下的性能,结果显示其趋势与 ACT 一致,即更多的动作分块可以提高性能。虽然 ACT 的性能仍然显著优于两种增强后的基线方法,但这些结果表明,在这些设置下,动作分块通常对模仿学习是有益的。

然后,我们通过比较有无时间集成时的最高成功率,来消除时间集成的影响,同样针对上述 4 个任务和不同的k 值进行比较。需要注意的是,有无时间集成的实验分别进行了参数调优:在无时间集成时表现最佳的超参数,在有时间集成时可能并非最优。如图 8(b) 示， BC-ConvMLP 从时间集成中获益最大,性能提升了 4%,其次是我们的方法,性能提升了 3.3%。

我们注意到非参数方法 VINN 的性能有所下降。我们推测,时间集成主要通过平滑建模误差来提升参数方法的性能。相比之下,VINN 从数据集中提取真实动作,因此不受此问题的影响。

B. 使用 CVAE 进行训练

我们使用 CVAE 目标函数训练 ACT,以模拟人类演示行为,这些行为可能包含噪声和多模态行为。在本节中,我们将训练后的 ACT 与未使用 CVAE 目标函数的 ACT 进行比较,后者仅根据当前观测结果预测一系列动作,并使用 L1 损失函数进行训练。如图 8所示。

Machine Translated by Google

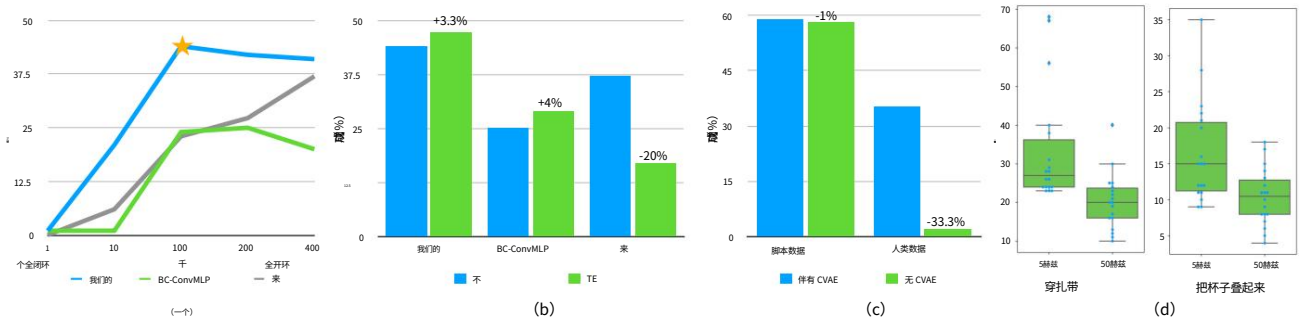

图 8： (a) 我们使用动作分块增强了两个基线方法， x 轴表示不同的分块大小k值， y 轴表示成功率。两种方法都显著受益于动作分块,表明它是一种普遍有效的技术。(b) 时间集成(TE) 改进了我们的方法和 BC-ConvMLP,但降低了 VINN 的性能。(c) 我们比较了使用和不使用 CVAE 训练的情况,表明 CVAE在从人类数据中学习时至关重要。(d) 我们绘制了用户研究中任务完成时间的分布图,其中我们要求参与者在 5Hz 或 50Hz 的远程操作频率下执行两项任务。降低频率导致完成时间延长了 62%。

(c) 我们将两个模拟任务的成功率汇总可视化,并分别绘制使用脚本数据和人类数据进行训练的结果。可以看出,在脚本数据上训练时,移除 CVAE 目标函数对性能几乎没有影响,因为数据集是完全确定性的。而对于人类数据,成功率则从 35.3% 显著下降到 2%。这表明,在从人类演示中学习时,CVAE 目标函数至关重要。

C. 高频是必要的吗?

最后,我们进行了一项用户研究,以说明高频远程操作对于精细操作的必要性。在相同的硬件配置下,我们将频率从 50Hz 降低到 5Hz,这一控制频率与近期使用高容量深度网络进行模仿学习的研究[7, 70]中所使用的频率相似。我们选择了两个精细任务:穿扎带和拆开两个塑料杯。这两个任务都需要毫米级的精度和闭环视觉反馈。我们招募了6 名参与者进行这项研究,他们的远程操作经验各不相同,但之前都没有使用过 ALOHA 。参与者均来自计算机科学 专业的硕士研究生,其中 4 名男性,2 名女性,年龄在 22 至 25 岁之间。每个参与者的任务顺序和频率都是随机的,并且在每次试验前都有 2 分钟的练习时间。我们记录了 3 次试验中完成任务所需的时间,并将数据可视化呈现在图 8 (d) 中。平均而言,参与者在 5Hz 频率下穿扎带需要 33 秒,而在 50Hz 频率下则缩短至 20 秒。对于分离塑料杯的任务,提高控制频率可将任务持续时间从 16 秒缩短至 10 秒。总体而言,我们的设置（即 50Hz)允许参与者在短时间内完成高度灵巧和精确的任务。然而,将频率从 50Hz 降低到 5Hz 会导致远程操作时间增加 62%。我们随后使用“重复测量设计”这一统计程序,正式验证了 50Hz 远程操作的性能优于 5Hz ,p 值 < 0.001。更多研究细节请参见附录 E。

七、局限性和结论

我们提出了一种用于精细操作的低成本系统,该系统包括远程操作系统ALOHA和一种新型的模仿技术。学习算法ACT。这两个部分的协同作用使我们能够在现实世界中直接学习精细操作技能,例如打开半透明的调味杯和安装电池,成功率高达80-90%,演示时间约为10分钟。虽然该系统功能强大,但仍有一些任务超出了机器人或学习算法的能力范围,例如扣衬衫纽扣。

我们在附录 F 中对局限性进行了更详细的讨论。总的来说,我们希望这个低成本的开源系统代表着朝着推进精细机器人操作迈出的重要一步,并成为一种易于获取的资源。

致谢

我们感谢斯坦福大学IRIS实验室成员的支持和反馈。我们还要感谢Siddharth Karamcheti、Toki Migimatsu、Staven Cao、Huihan Liu、Mandi Zhao、Pete Florence和Corey Lynch的有益讨论。Tony Zhao的研究得到了FANUC赞助的斯坦福机器人奖学金、Schmidt Futures基金以及ONR资助项目（编号N00014-21-1-2685)的支持。

参考

[1] Viperx 300 机器人手臂 6dof。网址https://www. trossenrobotics.com/viperx-300-robot-arm-6dof.aspx。

[2] Widowx 250 机器人手臂 6dof。网址https://www. trossenrobotics.com/widowx-250-robot-arm-6dof.aspx。

[3]高灵巧性操作系统 - 功能 -第一部分,2014 年 11 月。网址： https://www.youtube.com/watch?v= TearcKVj0iY。

[4]装配性能指标和测试方法,2022 年 4 月。URL https://www.nist.gov/el/intelligent-systems-division-73500/机器人抓取和操作组装/组装。

[5] 远程操作机器人 - shadow 远程操作系统， 2022 年 11 月。网址： https://www.shadowrobot.com/teleoperation/。

[6] Sridhar Pandian Arunachalam、Irmak Güzey、Soumith Chintala 和 Lerrel Pinto。Holo-dex:利用沉浸式混合现实教授灵巧性。arXiv 预印本 arXiv:2210.06463,2022 年。

[7]安东尼·布罗汉、诺亚·布朗、贾斯蒂斯·卡巴哈尔、叶夫根·切博塔尔、约瑟夫·达比斯、切尔西·芬、基尔萨纳

Machine Translated by Google

Gopalakrishnan、Karol Hausman、Alexander Herzog、 Jasmine Hsu、Julian Ibarz、Brian Ichter、Alex Irpan、Tomas Jackson、Sally Jesmonth、Nikhil J. Joshi、Ryan C. Julian、 Dmitry Kalashnikov、Yuheng Kuang、Isabel Leal、Kuang- Huei Lee、Sergey Levi、Yao、Deekshav、Utsav Malla Manjunath、Igor莫达奇、奥菲尔·纳胡姆、卡罗莱纳·帕拉达、乔迪琳·佩拉尔塔、艾米丽·佩雷斯、卡尔·珀奇、乔内尔·奎安宝、卡尼什卡·拉奥、迈克尔·S·柳、格雷西亚·萨拉查、潘纳格·R·桑克蒂、凯文·赛义德、贾斯皮尔·辛格、苏梅德·阿南德·斯通、奥斯汀·桑塔、克莱·洪、特兰、坦森特、文森特·范胡克、史蒂夫·维加、Quan Ho Vuong, F. 夏、特德·肖、彭旭、徐思春、于天河、布里安娜·齐特科维奇。Rt-1:用于大规模实际控制的机器人转换器。ArXiv,abs/2212.06817,2022 。

[8] Nicolas Carion、Francisco Massa、Gabriel Synnaeve、Nicolas Usunier、Alexander Kirillov 和 Sergey Zagoruyko。使用Transformer进行端到端目标检测。ArXiv， abs/2005.12872,2020。

[9] Yuanpei Chen, Yaodong Yang, Tianhao Wu, Shengjie Wang, Xidong Feng, Jiechuan Jiang, Stephen McAleer, Hao Dong, Zongqing Lu, and Song-Chun Zhu. Towards human-level bimanual dexterous manipulation with rein-forcement learning. ArXiv, abs/2206.08686, 2022.

[10] Rohan Chitnis、Shubham Tulsiani、Saurabh Gupta 和Abhinav Kumar Gupta。使用学习的任务模式进行高效的双手操作。2020 年 IEEE 国际机器人与自动化会议 (ICRA)，第 1149-1155 页,2019 年。

[11] Sudeep Dasari 和 Abhinav Kumar Gupta.用于单次视觉模仿的 Transformer。在2020 年机器人学习会议上。

[12] Pim de Haan、Dinesh Jayaraman 和 Sergey Levine。模仿学习中的因果混淆。载于《神经信息处理系统》,2019。

[13] Jacob Devlin、Ming-Wei Chang、Kenton Lee 和 Kristina Toutanova。BERT:用于语言理解的深度双向 Transformer 的预训练。ArXiv， abs/1810.04805,2019。

[14] Yan Duan、Marcin Andrychowicz、Bradly C. Stadie、 Jonathan Ho、Jonas Schneider、Ilya Sutskever、P. Abbeel和 Wojciech Zaremba。一次性模仿学习。ArXiv,abs/1703.07326,2017 年。

[15] Frederik Ebert、Yanlai Yang、Karl Schmeckpeper、 Bernadette Bucher、Georgios Georgakis、Kostas Daniilidis、 Chelsea Finn 和 Sergey Levine。桥接数据:通过跨域数据集促进机器人技能的泛化。ArXiv,abs/2109.13396,2021 年。

[16] Peter R. Florence、Lucas Manuelli 和 Russ Tedrake。视觉运动策略学习中的自监督对应关系。IEEE 机器人与自动化快报,5:492–499,2019。

[17] Peter R. Florence、Corey Lynch、Andy Zeng、Oscar Ramirez、Ayzaan Wahid、Laura Downs、Adrian S. Wong、 Johnny Lee、Igor Mordatch 和 Jonathan Tompson。隐式行为克隆。ArXiv,abs/2109.00137,2021。

[18] Aditya Ganapathi、Priya Sundaresan、Brijen Thananjeyan、Ashwin Balakrishna、Daniel Seita、Jennifer Grannen、Minho Hwang、Ryan Hoque、Joseph Gonzalez、Nawid Jamali、Katsu Yamane、Soshi Iba 和 Ken Goldberg。在模拟中学习密集视觉对应关系以实现真实织物的平滑和折叠。2021 年 IEEE 国际机器人与自动化会议 (ICRA),第 11515–11522 页,2020 年。

[19] Jennifer Grannen、Priya Sundaresan、Brijen Thananjeyan、 Jeffrey Ichnowski、Ashwin Balakrishna、Minho Hwang、 Vainavi Viswanath、Michael Laskey、Joseph Gonzalez和 Ken Goldberg。通过学习与任务相关的关键点来解开密集结。在 2020 年机器人学习会议上。

[20] Huy Ha 和 Shuran Song. Flingbot:动态操控在布料展开中的非理性有效性。ArXiv,abs/2105.03655,2021 年。

[21] Ankur Handa、Karl Van Wyk、Wei Yang、Jacky Liang、Yu -Wei Chao、Qian Wan、Stan Birchfield、Nathan D. Ratliff和 Dieter Fox。Dexpilot:基于视觉的灵巧机器人手-臂系统的远程操作。2020 年 IEEE 国际机器人与自动化会议(ICRA),第 9164–9170 页,2019 年。

[22] Kaiming He, X. Zhang, Shaoqing Ren, and Jian Sun. 用于图像识别的深度残差学习。2016 年 IEEE计算机视觉与模式识别会议(CVPR),第 770-778 页,2015 年。

[23] Irina Higgins、Loïc Matthey、Arka Pal、Christopher P. Burgess、Xavier Glorot、Matthew M. Botvinick、Shakir Mohamed 和 Alexander Lerchner。“beta-vae:使用约束变分框架学习基本视觉概念”。载于2016 年国际学习表征会议。

[24] Ryan Hoque、Ashwin Balakrishna、Ellen R. Novoseller、 Albert Wilcox、Daniel S. Brown 和 Ken Goldberg。Thriftydagger:面向交互式模仿学习的预算感知新颖性和风险门控。发表于 2021 年机器人学习会议。

[25]斯蒂芬·詹姆斯、迈克尔·布洛施和安德鲁·J·戴维森。用于少样本模仿学习的任务嵌入式控制网络。ArXiv,abs/1810.03237,2018。

[26] Eric Jang、Alex Irpan、Mohi Khansari、Daniel Kappler、 Frederik Ebert、Corey Lynch、Sergey Levine 和 Chelsea Finn。Bc-z:基于机器人模仿学习的零样本任务泛化。在2022 年机器人学习会议上。

[27] RG Jenness 和 CD Wicker。橡树岭国家实验室的主从机械臂和远程维护,1975 年 1 月。网址： https://www.osti.gov/biblio/4179544。

[28] Edward Johns. 从粗到精的模仿学习:从单次演示中学习机器人操作。2021 年 IEEE 国际机器人与自动化会议(ICRA),第 4613-4619 页,2021 年。

[29]柯立明、王景强、Tapomayukh Bhattacharjee 、Byron Boots 和 Siddhartha Srinivasa。“用筷子抓取:在无模型模仿学习中进行精细操作时对抗协变量偏移”。载于国际会议论文集。

Machine Translated by Google

2021 年机器人与自动化大会 (ICRA)。

[30] Michael Kelly、Chelsea Sidrane、K. Driggs-Campbell 和 Mykel J. Kochenderfer。“Hg-dagger:与人类专家进行交互式模仿学习”。2019 年国际机器人与自动化会议 (ICRA),第8077–8083 页,2018 年。

[31] Heecheol Kim,Yoshiyuki Ohmura,Yasuo Kuniyoshi。基于注视的双分辨率深度模仿学习实现高精度灵巧机器人操作。IEEE机器人与自动化快报,6:1630–1637,2021。

[32] Heecheol Kim,Yoshiyuki Ohmura,Yasuo Kuniyoshi。机器人利用目标条件双动作深度模仿学习剥香蕉。ArXiv,abs/2203.09749,2022。

[33]迪德里克·P·金马和马克斯·韦林。自动编码变分贝叶斯。 CoRR,abs/1312.6114,2013。

[34] Oliver Kroemer、Christian Daniel、Gerhard Neumann、Herke van Hoof 和 Jan Peters。面向多阶段操作任务的分层技能学习。

2015 年 IEEE 国际机器人与自动化会议 (ICRA),第 1503-1510 页,2015 年。

[35] Lucy Lai、Ann Z Huang 和 Samuel J Gershman。“动作分块作为策略压缩”,2022 年 9 月。网址psyarxiv。 com/z8yrv。

[36] Michael Laskey、Jonathan Lee、Roy Fox、Anca D. Dragan和 Ken Goldberg。Dart:用于鲁棒模仿学习的噪声注入。在 2017 年机器人学习会议上。

[37] Alex X. Lee、Henry Lu、Abhishek Gupta、Sergey Levine和 P. Abbeel。从多个演示中学习基于力的可变形物体操作。

2015 年 IEEE 国际机器人与自动化会议 (ICRA),第 177-184 页,2015 年。

[38]李维维. 生物运动系统的最优控制. 2006.

[39] Ajay Mandlekar、Danfei Xu、J. Wong、Soroush Nasiriany、Chen Wang、Rohun Kulkarni、Li Fei-Fei、Silvio Savarese、 Yuke Zhu 和 Roberto Mart in-Mart in。从离线人类演示中学习机器人操作的关键因素。载于 2021 年机器人学习会议。

[40] Kunal Menda、K. Driggs-Campbell 和 Mykel J. Kochenderfer 。“Ensembledagger:一种用于安全模仿学习的贝叶斯方法”。2019 年 IEEE/RSJ智能机器人与系统国际会议 (IROS),第 5041-5048 页,2018 年。

[41] Samuel Paradis、Minho Hwang、Brijen Thananjeyan、Jeffrey Ichnowski、Daniel Seita、Danyal Fer、Thomas Low、Joseph Gonzalez 和 Ken Goldberg。“间歇性视觉伺服:高效学习对器械变化具有鲁棒性的策略,用于高精度外科手术操作”。2021 年 IEEE 国际机器人与自动化会议 (ICRA),第 7166–7173 页,2020 年。

[42] Jyothish Pari、Nur Muhammad、Sridhar Pandian Arunacha- lam 和 Lerrel Pinto。表征学习在视觉模仿中的惊人有效性。arXiv 预印本 arXiv:2112.01511,2021 年。

[43]彼得·帕斯特、海科·霍夫曼、塔米姆·阿斯福和斯特凡 Schaal. 通过示范学习运动技能的学习和泛化。2009 年 IEEE 国际机器人与自动化会议,第 763-768 页， 2009 年。

[44] Dean A. Pomerleau. Alvinn:神经网络中的自主陆地车辆。NIPS,1988。

[45]秦宇哲,苏昊,王晓龙. 从单手到多手:基于单摄像头遥操作的灵巧操作模仿学习. IEEE机器人与自动化快报, 7:10873–10881, 2022.

[46] Rouhollah Rahmatizadeh、Pooya Abolghasemi、Ladislau Bölöni 和 Sergey Levine。基于视觉的多任务操作,利用端到端演示学习实现低成本机器人。2018 年 IEEE 国际机器人与自动化会议 (ICRA),第 3758–3765 页，2017 年。

[47] Stéphane Ross、Geoffrey J. Gordon 和 J. Andrew Bagnell。“将模仿学习和结构化预测简化为无悔在线学习”。载于2010 年国际人工智能与统计学会议论文集。

[48] Seyed Sina Mirrazavi Salehian、Nadia Figueroa 和 Aude Billard。“协调多臂运动规划的统一框架”。《国际机器人研究杂志》 ,37:1205 – 1232,2018。

[49] Nur Muhammad (Mahi) Shafiullah、Zichen Jeff Cui、Ariuntuya Altanzaya 和 Lerrel Pinto。行为变形金刚:用一颗石头克隆 k 种模式。 ArXiv， abs/2206.11251,2022。

[50] Kaushik Shivakumar、Vainavi Viswanath、Anrui Gu、Yahav Avigal、Justin Kerr、Jeffrey Ichnowski、Richard Cheng、Thomas Kollar 和 Ken Goldberg。Sgtm 2.0:利用交互式感知自主解开长电缆。ArXiv,abs/2209.13706,2022。

[51] Mohit Shridhar、Lucas Manuelli 和 Dieter Fox。Cliport:机器人操作的路径及其用途。ArXiv， abs/2109.12098,2021 年。

[52]莫希特·施里达尔、卢卡斯·曼努埃利和迪特·福克斯。感知器-执行器:用于机器人操作的多任务转换器。ArXiv,abs/2209.05451,2022。

[53] Aravind Sivakumar、Kenneth Shaw 和 Deepak Pathak。机器人心灵感应:通过观看 YouTube 上的人类视频学习机器人手的模仿。RSS,2022。

[54] Christian Smith、Yiannis Karayiannidis、Lazaros Nalpantidis 、Xavi Gratal、Peng Qi、Dimos V. Dimarogonas和 Danica Kragic。双臂操纵 - 一项调查。

机器人自主系统,60:1340–1353,2012。

[55] Kihyuk Sohn、Honglak Lee 和 Xinchen Yan.使用深度条件生成模型学习结构化输出表示。NIPS,2015。[56] srcteam. 影子远程操作系统玩叠叠乐，2021 年 3 月。网址： https://www.youtube.com/watch?v= 7K9brH27jvM。 [57] srcteam。研究人员如何使用影子机器人技术,2022年6月。网址： https://www.youtube.com/watch?v=p36fYIoTD8M。 [58] srcteam。影子远程操作系统,2022 年 6 月。URL

Machine Translated by Google

https://www.youtube.com/watch?v=cx8eznfDUJA.

[59] Simon Stepputtis、Maryam Bandari、Stefan Schaal 和Heni Ben Amor。“用于模仿学习接触丰富的双手动操作策略的系统”。2022 年IEEE/RSJ 国际智能机器人与系统会议 (IROS),第 11810–11817 页,2022 年。

[60] Priya Sundaresan、Jennifer Grannen、Brijen Thanan-jeyan、Ashwin Balakrishna、Jeffrey Ichnowski 和 Ellen R. Novoseller、Minho Hwang、Michael Laskey、Joseph Gonzalez和 Ken Goldberg。通过学习操作特征和恢复策略来解开稠密的非平面纽结。ArXiv，abs/2107.08942,2021。

[61] Gokul Swamy、Sanjiban Choudhury、J. Andrew Bagnell 和 Zhiwei Steven Wu。“时间相关噪声下的因果模仿学习”。载于2022 年国际机器学习会议。

[62] Naftali Tishby 和 Noga Zaslavsky。深度学习与信息瓶颈原理。2015 年 IEEE 信息论研讨会 (ITW),第 1-5 页,2015 年。

[63] Emanuel Todorov、Tom Erez 和 Yuval Tassa。Mujoco:基于模型的控制的物理引擎。2012 年 IEEE/RSJ智能机器人与系统国际会议,第 5026-5033 页，2012 年。

[64] Stephen Tu、Alexander Robey、Tingnan Zhang 和 N. Matni。关于稳定性约束模仿学习的样本复杂度。在2021 年动力学与控制学习会议上。

[65] Ashish Vaswani、Noam M. Shazeer、Niki Parmar、Jacob Uszkoreit、Llion Jones、Aidan N. Gomez、Lukasz Kaiser和 Illia Polosukhin。您所需要的就是关注。 ArXiv， abs/1706.03762,2017。

[66] Solomon Wiznitzer、Luke Schmitt 和 Matt Trossen。interbotix_ros_manipulators。网址： https://github.com/ Interbotix/interbotix_ros_manipulators。

[67] Fan Xie, AM Masum Bulbul Chowdhury, M. Clara De Paolis Kaluza, Linfeng Zhao, Lawson LS Wong和 Rose Yu. 用于双手动机器人操作的深度模仿学习. ArXiv, abs/2010.05134, 2020.

[68] Andy Zeng、Peter R. Florence、Jonathan Tompson、Stefan Welker、Jonathan Chien、Maria Attarian、Travis Armstrong、 Ivan Krasin、Dan Duong、Vikas Sindhwani 和 Johnny Lee。“运输网络:为机器人操作重新排列视觉世界”。载于2020 年机器人学习会议。

[69] Tianhao Zhang, Zoe McCarthy, Owen Jow, Dennis Lee, Ken Goldberg 和 P. Abbeel. 基于虚拟现实远程操作的复杂操作任务的深度模仿学习. 2018 年 IEEE 国际机器人与自动化会议 (ICRA),第 1-8 页,2017 年。

[70] Allan Zhou、Moo Jin Kim、Lirui Wang、Peter R. Florence和 Chelsea Finn。“掌中 Nerf:通过新颖视角合成实现机器人矫正增强”。arXiv,abs/2301.08556,2023。[71] Áron Horváth、Eszter Ferentzi、Kristóf Schwartz、Nina Jacobs、Pieter Meyns 和 Ferenc Köteles。“本体感觉准确性的测量:系统文献综述”综述。《运动与健康科学杂志》,2022 年。ISSN 2095-2546。doi：https://doi.org/10.1016/j.jshs.2022.04。001. URL https://www.sciencedirect.com/science/article/pii/S2095254622000473。

Machine Translated by Google

附录

A. 将 ALOHA 与之前的远程操作设置进行比较

图 9 展示了 ALOHA能够执行的更多远程操作任务。我们强调,所有对象均直接取自现实世界,未做任何修改,以证明ALOHA 在实际应用场景中的通用性。

ALOHA 利用领队机器人和跟随机器人之间的运动相似性,通过关节空间映射进行远程操作。

领导者-跟随者设计方案至少可以追溯到1953年,当时中央研究实验室（Central Research Laboratories)开发了用于处理危险材料的远程操作系统[27]。近年来,像RE2 [3]这样的公司也开发了具有关节空间映射功能的高灵巧度远程操作系统。ALOHA与这些早期系统类似,同时受益于低成本执行器和机械臂的最新进展。它使我们能够以更低的成本实现类似的灵巧度,而且无需专用硬件或专家组装。

接下来,我们将ALOHA的成本与近期的远程操作系统进行比较。DexPilot [21]利用人手的图像流来控制灵巧的机械手。它使用4个经过校准的Intel RealSense传感器来捕捉人手的点云,并将姿态重新定向到Allegro机械手上。Allegro机械手随后被安装在KUKA LBR iiwa7 R800机器人上。DexPilot能够完成一些令人印象深刻的任务,例如从钱包里取出钱、打开花生罐以及在NIST 1号板上进行插入操作。我们估计,包含一只机械臂和一只机械手的系统成本约为10万美元。一些更新的研究,例如Robotic Telekinesis [53, 6, 45] ,试图通过使用单个RGB摄像头来检测手部姿态,并利用学习技术进行重新定向,从而降低DexPilot的成本。虽然传感成本大大降低,但机械手和机械臂的成本仍然很高:灵巧的机械手具有更多的自由度,因此价格自然也更高。移动机械手还需要一个有效载荷至少为 2 公斤的工业机械臂,这将进一步增加成本。我们估计,包含一只机械臂和一只机械手的系统成本约为 1.8 万美元。最后,Shadow 远程操作系统是一个用于远程操控两只灵巧机械手的双手系统。两只机械手都安装在 UR10 机器人上,手部姿态通过追踪手套或触觉手套来获取。

在上述所有方案中,该系统功能最为强大,这得益于其双臂式设计。然而,它的成本也最高,至少需要40万美元。相比之下,ALOHA也是一套双臂式系统,成本为1.8万美元（添加摄像头等可选配件后为2万美元）。将灵巧的机械手简化为平行颚式夹爪,使我们能够使用轻便且低成本的机器人,这些机器人更加灵活,所需的维护也更少。

最后,我们将ALOHA的功能与之前的系统进行比较。我们选择功能最强大的系统作为参考： Shadow远程操作系统[5],其成本是ALOHA的10倍以上。具体来说,我们找到了三个演示视频[56, 57, 58] ,其中包含Shadow远程操作系统的15个用例,并尝试使用ALOHA重现这些用例。

这些任务包括玩“啤酒乒乓”、“叠叠乐”和魔方,使用簸箕和刷子,拧开水瓶,倒出液体,解开魔术贴扎带,捡起鸡蛋和灯泡,插拔USB和RJ45接口,使用……

使用移液器、书写、拧开铝盒以及手持旋转保定球。我们能够用类似的物体和相近的时间重现15项任务中的14项。

我们无法重现保定球在手中旋转的任务,因为我们的装置没有手。

B. 示例图像观察

图 10 展示了策略执行期间针对 6 个实际任务拍摄的示例图像。从左到右,这 4 张图像分别来自顶部摄像头、前置摄像头、左手腕和右手腕。顶部摄像头和前置摄像头保持静止,而手腕摄像头随机器人移动,提供机械臂的详细视图。我们还将前置摄像头旋转了 90 度,以捕捉更多垂直空间。所有摄像头的焦距均固定,并开启自动曝光功能以适应不断变化的光照条件。所有摄像头均以480 × 640 分辨率和30fps 的帧率进行视频流传输。

C. 详细架构图我们在图 11 中包含了一

个更详细的架构图。

在训练阶段,我们首先采样RGB图像和关节位置的元组,以及相应的动作序列作为预测目标（步骤1:采样数据）。然后,我们使用图中黄色所示的CVAE编码器推断风格变量z （步骤2:推断z）。编码器的输入包括:1)[CLS]标记,它由随机初始化的学习权重组成;2)嵌入的关节位置,它是使用线性层投影到嵌入维度上的关节位置;3）嵌入的动作序列,它是使用另一个线性层投影到嵌入维度上的动作序列。这些输入构成一个(k + 2) × 嵌入维度的序列,并由Transformer编码器进行处理。我们仅取第一个输出,即对应于[CLS]标记的输出,并使用另一个线性网络来预测z分布的均值和方差,将其参数化为对角高斯分布。使用重新参数化获得z的样本,这是一种允许通过采样过程进行反向传播的标准方法,以便编码器和解码器可以联合优化[33]。

接下来,我们尝试从CVAE解码器中获取预测动作,即策略（步骤3:预测动作序列）。对于每幅图像观测值,首先使用ResNet18进行处理以获得特征图,然后将其展平以获得特征序列。这些特征通过线性层投影到嵌入维度,并添加一个二维正弦位置嵌入以保留空间信息。然后,将来自每个摄像头的特征序列连接起来,作为Transformer编码器的输入。

另外两个输入是关节位置和z轴,它们也分别通过两个线性层投影到嵌入维度。Transformer编码器的输出随后被用作Transformer解码器交叉注意力层的“键”和“值” ,解码器根据编码器的输出预测动作序列。“查询”是第一层的固定正弦嵌入。

在测试阶段,CVAE编码器（图中黄色部分)被舍弃,而CVAE解码器被用作策略。

Machine Translated by Google

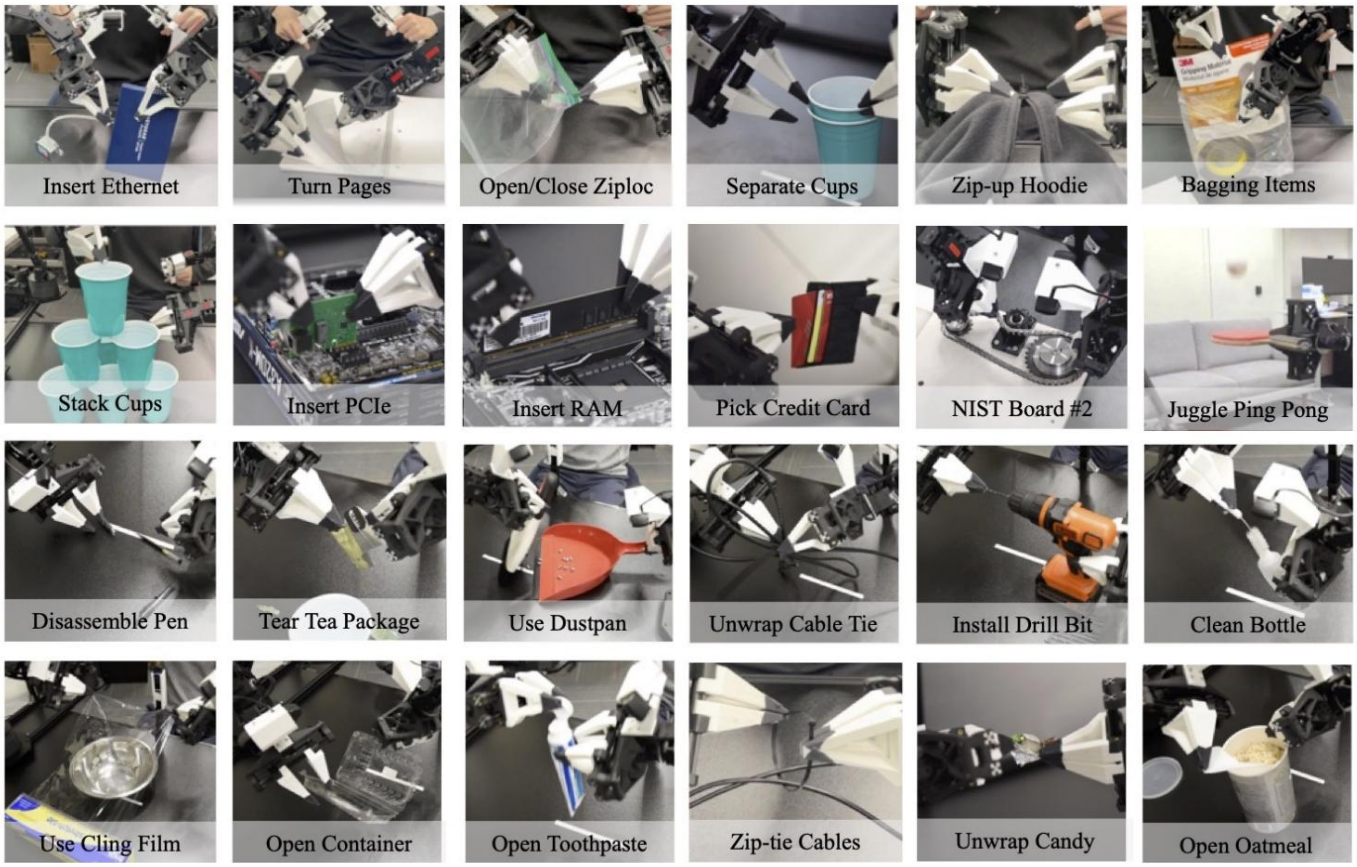

图 9： ALOHA 的远程操作任务示例。我们在项目网站上提供了相关视频。

输入的观测数据（图像和关节)与训练时输入模型的方式相同。唯一的区别在于z,它代表我们希望从策略中提取的动作序列的“风格” 。我们只需将z设置为零向量,即训练时使用的单位高斯先验的均值。因此,给定一个观测数据,策略的输出始终是确定性的,这有利于策略评估。

D. 实验细节和超参数

我们仔细调整了基线模型,并采用了表 III、IV、V、VI 和 VII 中使用的超参数。对于 BeT 算法,我们发现将历史长度从 10（与原始论文相同)增加到 100 可以显著提高性能。较大的隐藏维度通常也有帮助。对于 VINN 算法,检索最近邻时使用的 k 值是根据验证损失最小的自适应方法选择的,与原始论文相同。我们还发现,当不存在动作分块时（此时检索动作时的状态权重为 10）,除了视觉特征相似性之外,使用关节位置差异也能提高性能。然而,我们发现这样做会损害动作组块的性能,因此在动作组块实验中将状态权重设置为 0。

E. 用户研究详情我们对6

名计算机科学专业研究生进行了用户研究,其中4名男性,2名女性,年龄在22至25岁之间。3名参与者有相关经验。其中一名参与者使用VR控制器远程操控机器人,而另外三名参与者此前没有远程操控经验。所有参与者之前均未使用过ALOHA协议。为了实现5Hz版本的ALOHA协议,我们以5Hz的频率从主导机器人读取数据,在关节空间进行插值,并以50Hz的频率将插值后的位置发送给机器人。我们选择的任务强调高精度和闭环视觉反馈。图12展示了所用物体的图像。例如,在穿扎带任务中,孔径为4mm x 1.5mm,扎带尺寸为0.8mm x 3.5mm,末端尖锐。扎带初始平放在桌面上,操作员需要用一只机械手夹住扎带,在空中抓住另一端,然后双手协调将扎带的一端插入另一端的孔中。在拆叠杯子任务中,我们使用了两个一次性塑料杯,堆叠时杯间距为2.5mm。远程操作员需要抓住上层杯子的边缘,然后通过摇晃使其分离,或者借助另一个夹爪的帮助。在用户研究中,我们随机化操作员尝试每项任务的顺序,以及他们先使用 50Hz 控制器还是 5Hz 控制器。我们还随机化了物体在工作台中心周围的初始位置。

对于每个设置,操作员有 2 分钟的适应时间,然后连续尝试执行该任务 3 次,并记录持续时间。

F. 局限性

我们现在讨论ALOHA硬件的局限性,利用 ACT 进行政策学习。

Machine Translated by Google

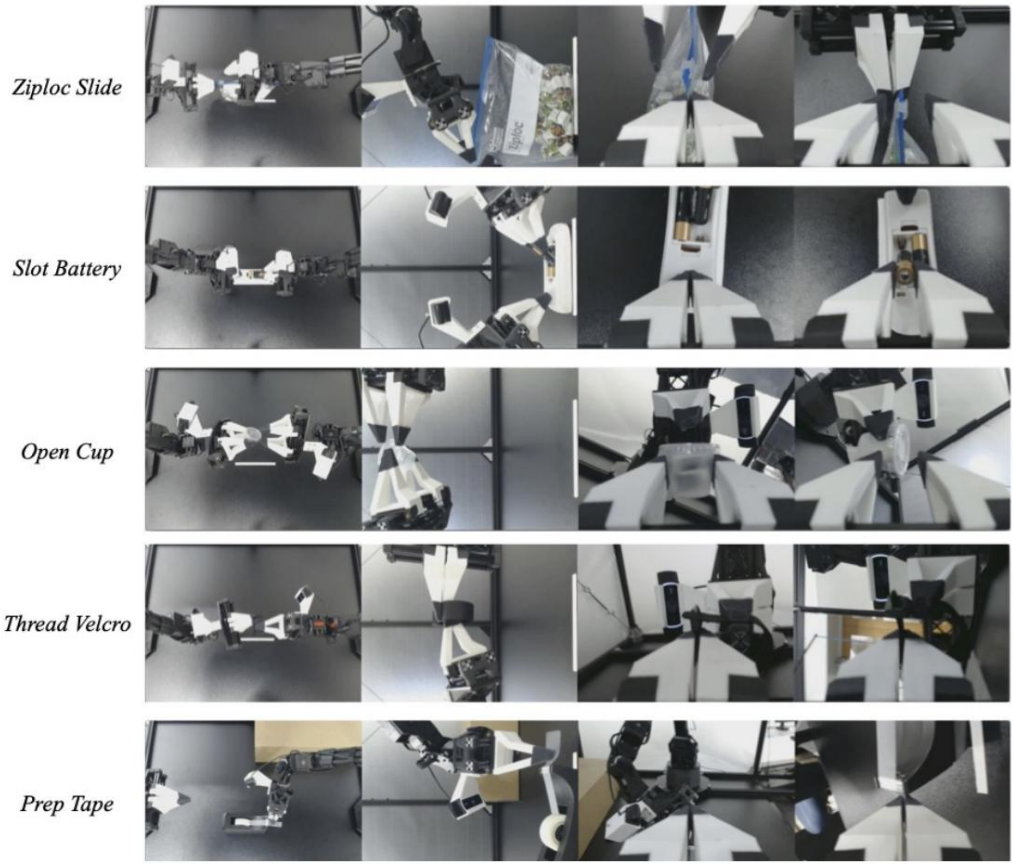

图 10： 5 个实际任务的图像观察示例。图中 4 列分别代表 [顶部摄像头、前置摄像头、左手腕摄像头、右手腕摄像头]。我们将前置摄像头旋转 90 度以捕捉更多垂直空间。

硬件限制。在硬件方面,ALOHA 在处理需要双手多指操作的任务时表现不佳,例如打开带有按压拉环的儿童安全药瓶。要打开药瓶,一只手需要握住瓶身并向下按压拉环,另一只手则需要旋转瓶盖将其打开。ALOHA 在处理需要较大力的任务时也表现不佳,例如举起重物、旋转打开密封的瓶装水或打开紧密闭合的记号笔笔帽。这是因为低成本电机无法产生足够的扭矩来支持这些操作。

即使我们将抓取器设计成边缘很薄， ALOHA 仍然难以完成需要用到指甲的任务。
例如,我们无法掀起粘在一起的包装胶带的边缘,也无法打开铝制汽水罐。

策略学习局限性。在软件方面,我们报告了ACT在尝试的两项任务中未能学习到相关行为的情况。第一项任务是拆糖果包装。具体步骤包括从桌上拿起糖果,拉住糖果的两端,然后撬开包装露出糖果。我们收集了50个演示数据来训练ACT策略。在包含10次试验的初步评估中,该策略拿起糖果的成功率为10/10,拉住糖果两端的成功率为8/10,而拆开糖果包装的成功率为0/10。我们将失败归因于感知难度和数据不足。具体来说,在拉住糖果两端之后,用于撬开糖纸的接缝可能出现在糖果周围的任何位置。在演示收集过程中,即使是人也很难辨别。操作员需要通过观察糖纸上的图案来判断并找到接缝的断点。我们不断观察到,该策略试图从接缝不存在的地方剥开糖纸。为了更好地跟踪进展,我们尝试了另一种评估方法,对每种糖果进行 10 次试验,并对 5 种糖果重复此过程。在此方案下,我们的策略成功打开了 5 颗糖果中的 3 颗。

ACT在另一项任务上也遇到了困难:打开平放在桌面上的小型自封袋。右手机械臂需要先拿起袋子,调整位置,使左手机械臂能够牢牢抓住袋子的拉动区域,然后右手抓住拉动区域的另一侧,最后将袋子拉开。我们用50个演示数据训练的策略能够稳定地拿起袋子,但在执行接下来的三个空中操作步骤时却遇到了困难。我们推测,袋子难以被感知,此外,拿起袋子位置的细微差别也会影响袋子的形变,最终导致拉动区域的位置出现较大差异。我们认为,预训练、更多的数据以及更佳的感知能力是解决这些极其困难任务的有效途径。

Machine Translated by Google

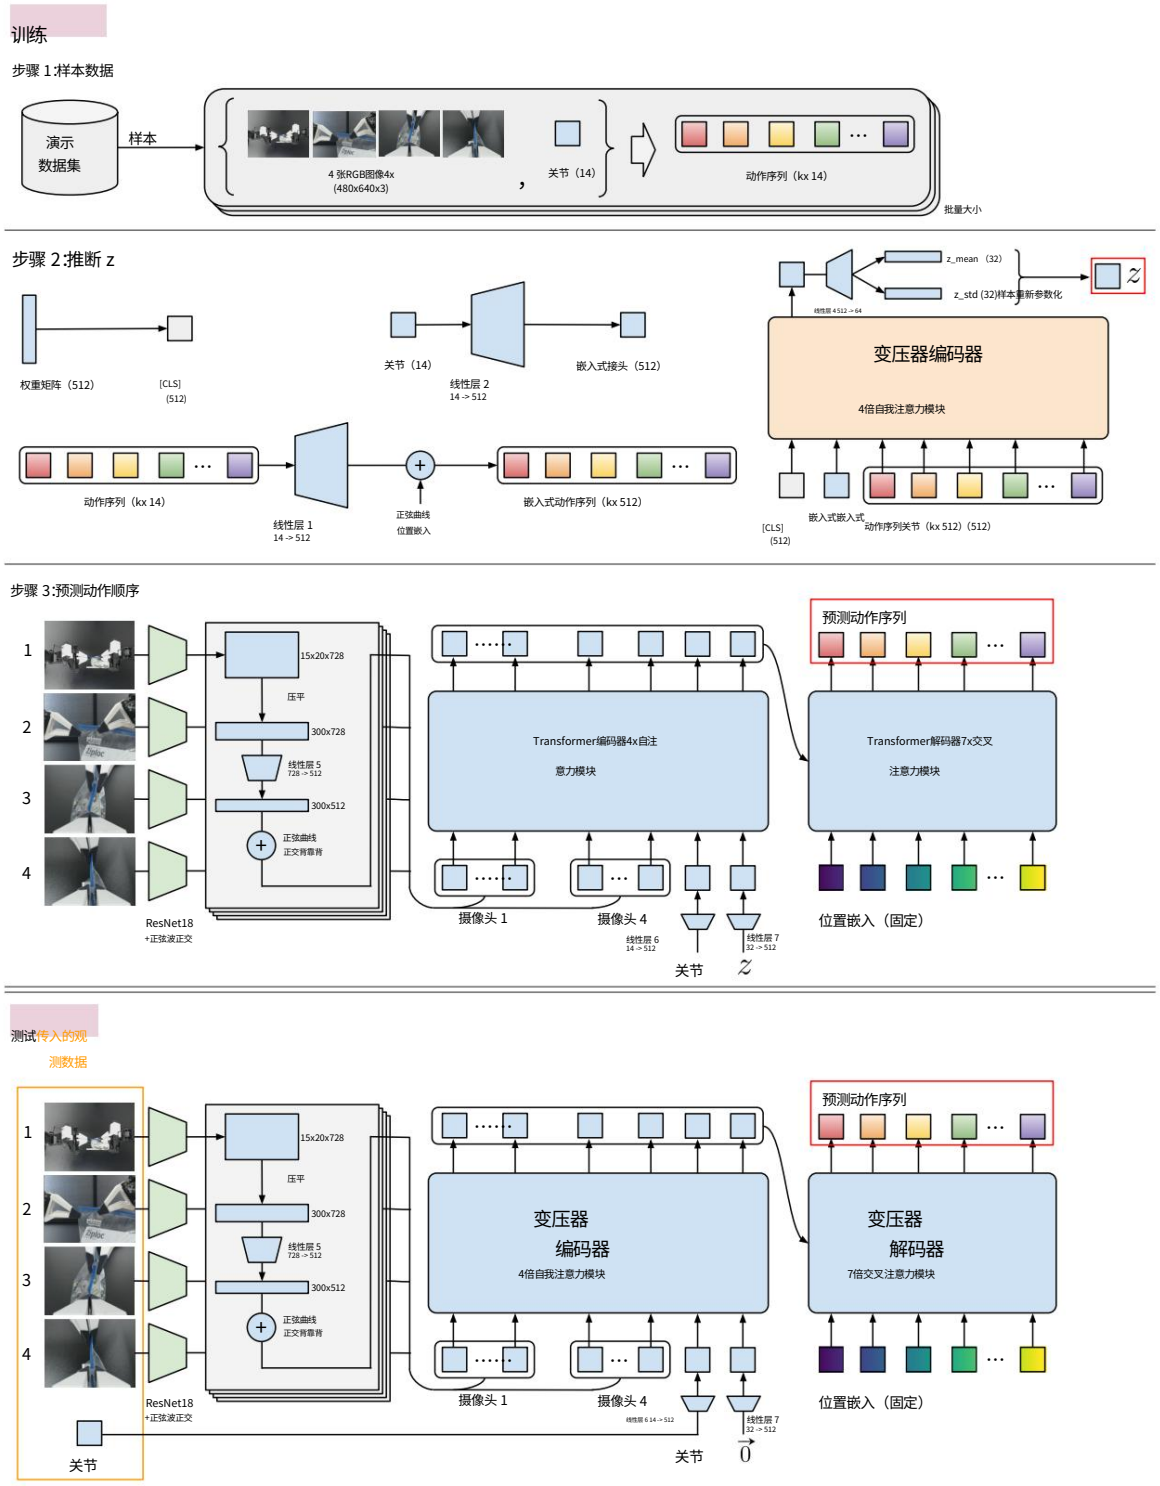

图 11:使用 Transformers 的动作分块（ACT)的详细架构。

Machine Translated by Google

图 12:用于用户研究的电缆扎带和杯子。

学习率 批次大小 #	1e-5
编码器层数 #	8
解码器层数 前馈维度 隐	4
藏维度 # 头部 块大小	7
beta dropout	3200
	512
	8
	100
	10
	0.1

表 III： ACT 的超参数。

学习率 批次大小	3e-4
轮数	128
	100
势头	0.9
体重下降	1.5e-6

表 IV： VINN 和 BeT 的特征提取器 BYOL 的超参数。

学习率 批次大小	1e-4
# 层数 # 头部	64
数 隐藏维	6
度 历史长	6
度 权重衰减 偏移损失	768
缩放 焦点损失 伽	100
马缺失 离散化器	0.1
#箱数	1000
	2
	0.1
	64

表 V： BeT 的超参数。

k（最近邻)状态权重	自适应
	0 或 10

表 VI： WIN 的超参数。

学习率批次大小	1e-5
	2
ViT 暗头	32
ViT窗口大小	7
ViT mbconv 扩展率	4
ViT mbconv 收缩率	0.25
ViT辍学	0.1
RT-1深度	6
RT-1 头部	8
RT-1 暗头	64
RT-1 动作箱	256
RT-1 条件下降问题	0.2
RT-1 令牌学习器 输出令牌数 权重衰减历史长度	8
	0
	6

表七： RT-1 的超参数。