

使用低成本硬件学习精细双手操作

Tony Z. Zhao, Vikash Kumar, Sergey Levine, Chelsea Finn

斯坦福大学, 加州大学伯克利分校, Meta

摘要

精细操作任务，例如穿过扎带或将电池插入卡槽，对机器人而言是出了名的困难，因为这些任务需要高精度、接触力的精确协调以及闭环视觉反馈。执行这些任务通常需要高端机器人、精密传感器或细致的校准，这些设备造价昂贵且难以搭建。学习能否使低成本、不精确的硬件完成这些精细操作任务呢？本文提出了一种低成本系统，能够利用自定义遥操作界面收集的真实示范数据，直接进行端到端的模仿学习。然而，模仿学习本身也面临挑战，特别是在高精度领域：策略误差会随时间累积，而人类示范数据可能具有非平稳性。为了应对这些挑战，我们开发了一种简单而新颖的算法——基于Transformer的动作分块（Action Chunking with Transformers, ACT），该算法学习动作序列的生成模型。ACT使机器人能够在真实世界中学习6项困难任务，例如打开半透明调味杯和插入电池，成功率可达80-90%，而仅需约10分钟的示范数据。

一、引言

精细操作任务涉及精确的闭环反馈，需要高度的视觉-运动协调能力，以根据环境变化进行调整和重新规划。此类操作任务的例子包括打开调味杯盖或插入电池，它们涉及捏取、撬动、撕裂等精细动作，而非拾取和放置等粗粒度动作。以图1中打开调味杯盖为例：杯子初始直立于桌面上，右侧夹爪需要先将其推倒，并推入已打开的左侧夹爪。然后左侧夹爪轻轻合拢并将杯子抬起。接下来，右侧手指从下方接近杯子并撬开杯盖。这些步骤每一步都需要高精度、精细的视觉-运动协调和丰富的接触力反馈。毫米级的误差就可能导致任务失败。

现有的精细操作系统使用昂贵的机器人和高端传感器进行精确的状态估计。在本研究中，我们试图开发一种低成本且易于复现的精细操作系统的感知和规划挑战更加突出。一个有前景的解决方向是将学习引入系统。人类同样不具备工业级的本体感觉能力，但我们能够通过闭环视觉反馈学习和主动补偿误差来执行精细任务。因此，在我们的系统中，我们训练一个端到端策略，将商用网络摄像头的RGB图像直接映射到动作。这种从像素到动作的方案特别适合精细操作，因为精细操作通常涉及具有复杂物理属性的物体，学习操作策略比建立整个环境的模型要简单得多。

然而，训练端到端策略也面临自身特有的挑战。策略的性能严重依赖于训练数据分布，在精细操作场景中，高质量的人类示范数据具有巨大价值，它允许系统学习人类的灵巧性。因此，我们构建了一个低成本但灵巧的遥操作系统用于数据收集，以及一种新颖的模仿学习算法，能够有效地从示范数据中学习。

遥操作系统方面，我们设计了一个由两套低成本、现成机器人手臂组成的遥操作装置。它们近似为彼此的缩放版本，我们使用关节空间映射进行遥操作。我们用3D打印组件增强了该装置以便于反向驱动，最终在2万美元的预算内实现了高能力的遥操作系统。

模仿学习算法方面，需要精度和视觉反馈的任务对模仿学习构成了重大挑战，即使有高质量的示范数据也是如此。预测动作中的微小误差可能导致状态的巨大差异，加剧模仿学习的“复合误差”问题。为解决此问题，我们从心理学中的动作分块概念中获得启发——该概念描述了如何将一系列动作组合在一起作为一个整体来执行。在我们的方案中，策略预测接下来 k 个时间步的目标关节位置，而非一次只预测一步。这将任务的有效时间跨度缩短了 k 倍，从而缓解了复合误差问题。预测动作序列还有助于处理时间相关的混淆因素，例如示范中难以用马尔可夫单步策略建模的停顿。为了进一步提高策略的平滑性，我们提出了时间集成方法，以更高频率查询策略，并对重叠的动作分块进行加权平均。我们使用Transformer架构来实现动作分块策略，并将其作为条件变分自编码器（CVAE）进行训练，以捕捉人类数据的变异性。我们将该方法命名为基于Transformer的动作分块（ACT），发现在一系列仿真和真实世界的精细操作任务上，它显著优于先前的模仿学习算法。

本文的关键贡献是一个用于学习精细操作的低成本系统，包括遥操作系统和一种新颖的模仿学习算法。该系统允许在真实世界中直接学习6项精细操作技能，例如打开半透明调味杯和插入电池，成功率达80-90%，仅需约10分钟或50条示范轨迹。

二、相关工作

机器人操作中的模仿学习。模仿学习允许机器人直接向专家学习。行为克隆（BC）是最简单的模仿学习算法之一，将模仿转化为从观测到动作的监督学习。许多后续工作试图改进BC，例如通过不同架构引入历史信息、使用不同的训练目标以及引入正则化。其他工作强调模仿学习的多任务或少样本特性，利用语言信息或利用特定任务结构。用更多数据扩展这些模仿学习算法已经催生了令人印象深刻的系统，能够泛化到新的物体、指令或场景。在本研究中，我们专注于构建一个低成本且能够执行精细操作任务的模仿学习系统。

解决复合误差。BC的一个主要缺点是复合误差，即先前时间步的误差不断累积，导致机器人偏离训练分布，进入难以恢复的状态。这个问题在精细操作场景中尤为突出。一种缓解复合误差的方法是引入额外的在线策略交互和专家纠正，例如DAgger及其变体。然而，专家标注在遥操作界面下可能既耗时又不自然。也可以在数据收集时注入噪声以获取包含纠正行为的数据集，但在精细操作中，噪声注入可能导致任务失败，降低遥操作系统的灵巧性。我们提出通过动作分块来缩短任务的有效时间跨度，然后对重叠的动作分块进行集成，产生既准确又平滑的轨迹。

双手操作。双手操作在机器人学领域有着悠久的历史。早期工作从经典控制角度解决双手操作问题，依赖已知的环境动力学模型，但设计此类模型可能非常耗时。近年来，学习被引入双手系统，如强化学习、模仿人类示范或学习预测连接运动基元的关键点。一些工作也关注精细操作任务，如解开绳结、铺平布料甚至穿针引线，但使用了昂贵得多的机器人，如达芬奇手术机器人或ABB YuMi。我们的工作转向低成本硬件，旨在使低成本设备能够执行高精度闭环任务。

三、ALOHA：低成本开源双手遥操作硬件系统

我们致力于开发一个易于获取且高性能的精细操作遥操作系统。我们将设计考虑总结为以下5项原则：

- 1) 低成本：整个系统应在大多数机器人实验室的预算范围内，与单个工业机械臂相当。
- 2) 通用性：能够应用于各种真实物体的精细操作任务。

- 3) 用户友好：系统应直观、可靠且易于使用。
- 4) 可维修性：当不可避免地出现故障时，研究人员可以轻松修复。
- 5) 易于搭建：研究人员可以使用易于获取的材料快速组装。

根据原则1、4和5，我们选择使用两台ViperX 6自由度机器人手臂构建双手平行夹爪装置。ViperX机械臂的有效负载为750g，臂展1.5m，精度为5-8mm。该机器人可现成购买，价格约为5600美元。我们设计了3D打印的"透明"手指并贴上防滑胶带，在执行精细操作时提供良好的视野，即使面对薄塑料膜也能保持牢固的夹持。

我们使用直接关节空间映射而非任务空间映射来进行遥操作，使用同公司制造的小型WidowX机器人（价格约3300美元）作为主端。用户通过反向驱动较小的WidowX（"主臂"）进行遥操作，其关节与较大的ViperX（"从臂"）同步。相比任务空间映射，关节空间映射有以下优势：（1）精细操作通常需要在机器人奇异点附近操作，现成的逆运动学在此场景下经常失败。关节空间映射保证在关节限位内的高带宽控制，同时减少计算量和延迟。（2）主臂的重量防止用户移动过快，同时也抑制了小幅振动。

为进一步改善遥操作体验，我们设计了一种可安装到主臂的3D打印"手柄和剪刀"机构，降低了反向驱动所需的力，并允许连续控制夹爪而非简单的开合。我们还设计了橡皮筋负载平衡机构，部分抵消主臂的重力。系统的其余部分包括由铝型材搭建的机器人笼架，辅以交叉钢缆加固。共有四个罗技C922x网络摄像头，各自输出480x640的RGB图像。遥操作和数据记录均在50Hz频率下进行。

基于上述设计，我们在2万美元预算内构建了双手遥操作系统ALOHA。ALOHA能够遥操作执行精密任务（如穿过扎带）、丰富接触任务（如插入288针内存条）和动态任务（如用乒乓球拍颠球）。

四、基于Transformer的动作分块（ACT）

正如第五节将展示的，现有的模仿学习算法在高频控制和闭环反馈的精细任务上表现不佳。因此，我们开发了新算法ACT，以利用ALOHA收集的数据。

要在新任务上训练ACT，首先使用ALOHA收集人类示范数据。我们记录主臂的关节位置并将其作为动作。观测包括从臂的当前关节位置和4个摄像头的图像输入。接下来，训练ACT根据当前观测预测未来的动作序列。此处的动作对应于下一步两臂的目标关节位置。直观地说，ACT试图模仿在当前观测下人类操作者在随后几个时间步会执行的操作。这些目标关节位置由Dynamixel电机内部的低级高频PID控制器跟踪。在测试时，我们加载验证损失最低的策略并在环境中部署。

A. 动作分块与时间集成

为了以兼容像素到动作策略的方式对抗模仿学习的复合误差，我们寻求缩短高频采集的长轨迹的有效时间跨度。我们从神经科学中的动作分块概念获得启发——单个动作被组合在一起作为一个单元执行，使其存储和执行更加高效。直观地，一个动作分块可以对应于抓住糖果包装袋的一个角或将电池插入卡槽。

在我们的实现中，分块大小固定为 k ：每 k 步，智能体接收一次观测，生成接下来的 k 个动作，并按顺序执行。这意味着任务的有效时间跨度缩短为原来的 $1/k$ 。具体来说，策略建模的是 $\pi_{\theta}(a_t:t+k|s_t)$ 而非

$\pi\theta(at|st)$ 。分块还可以帮助建模人类示范中的非马尔可夫行为。具体而言，单步策略难以处理时间相关的混淆因素，例如示范中间的停顿，因为行为不仅取决于状态，还取决于时间步。当混淆因素包含在一个分块内时，动作分块可以缓解这一问题。

动作分块的朴素实现可能不够优化：每k步突然引入新的环境观测，可能导致机器人运动不平稳。为提高平滑性并避免执行和观测之间的离散切换，我们在每个时间步都查询策略。这使得不同的动作分块相互重叠，在给定时间步会有多个预测的动作。我们提出时间集成方法，使用指数加权方案 $w_i = \exp(-m \cdot i)$ 对这些预测进行加权平均，其中 w_0 是最老动作的权重。新观测的融入速度由 m 控制， m 越小意味着融合越快。值得注意的是，与典型的平滑方法不同，我们对预测的同一时间步的动作进行聚合，这不会引入偏差。此过程也不产生额外的训练成本，仅增加推理时的计算量。在实践中，我们发现动作分块和时间集成对ACT的成功都至关重要。

B. 建模人类数据

另一个挑战是从含噪的人类示范中学习。给定相同的观测，人类可以使用不同的轨迹来完成任务。人类在精度要求较低的区域也会表现出更大的随机性。因此，策略需要关注高精度要求区域的行为，这一点很重要。我们通过将动作分块策略训练为生成模型来解决这个问题。具体来说，我们将策略训练为条件变分自编码器（CVAE），以在给定当前观测的条件下生成动作序列。

CVAE包含两个组件：CVAE编码器和CVAE解码器。CVAE编码器仅在训练时用于训练CVAE解码器（即策略），在测试时被丢弃。具体来说，CVAE编码器在给定当前观测和动作序列作为输入的情况下，预测风格变量 z 的分布的均值和方差，该分布参数化为对角高斯分布。CVAE解码器（即策略）以 z 和当前观测（图像+关节位置）为条件来预测动作序列。在测试时，我们将 z 设置为先验分布的均值即零向量，以实现确定性解码。整个模型的训练目标是最大化示范动作分块的对数似然，使用标准的VAE目标函数，包含两个项：重构损失和将编码器正则化为高斯先验的项。我们用超参数 β 对第二项进行加权。直观地说，较高的 β 会导致 z 中传递的信息更少。总体而言，我们发现CVAE目标对于从人类示范中学习精确任务至关重要。

C. ACT的实现

我们使用Transformer来实现CVAE编码器和解码器。CVAE编码器使用类BERT的Transformer编码器实现。编码器的输入是当前关节位置和来自示范数据集的长度为 k 的目标动作序列，前面加上一个可学习的 "[CLS]" 标记。这形成了一个 $k+2$ 长度的输入。经过Transformer处理后，"[CLS]" 对应的特征用于预测风格变量 z 的均值和方差，然后 z 作为解码器的输入。

CVAE解码器（即策略）以当前观测和 z 为输入，预测接下来的 k 个动作。我们使用ResNet图像编码器、Transformer编码器和Transformer解码器来实现CVAE解码器。直观地说，Transformer编码器综合来自不同相机视角、关节位置和风格变量的信息，Transformer解码器生成连贯的动作序列。

观测包括4张RGB图像，分辨率为480x640，以及两台机器人手臂的关节位置（共 $7+7=14$ 个自由度）。动作空间是两台机器人的绝对关节位置，即14维向量。策略首先使用ResNet18骨干网络处理图像，将480x640x3的RGB图像转换为15x20x512的特征图。然后沿空间维度展平，得到300x512的序列。为保

留空间信息，我们在特征序列上添加二维正弦位置编码。对所有4张图像重复此操作，得到1200x512的特征序列。然后我们附加两个额外的特征：当前关节位置和风格变量 z ，分别通过线性层投影到512维。因此，Transformer编码器的输入为1202x512。Transformer解码器通过交叉注意力以编码器输出为条件，其输入序列是固定的位置编码，维度为 $k \times 512$ 。Transformer解码器的输出维度为 $k \times 512$ ，然后通过MLP降维到 $k \times 14$ ，对应于接下来 k 步的预测目标关节位置。

我们使用L1损失而非更常见的L2损失进行重构，因为我们发现L1损失能更精确地建模动作序列。模型约有8000万参数，我们为每个任务从头开始训练。训练在单张11G RTX 2080 Ti GPU上约需5小时，推理时间在同一机器上约为0.01秒。

五、实验

我们通过实验评估ACT在精细操作任务上的性能。为便于复现，我们在MuJoCo中构建了两个仿真精细操作任务，此外还有6个使用ALOHA的真实世界任务。

A. 任务

全部8个任务都需要精细的双手操作。对于Slide Ziploc（拉开密封袋），右侧夹爪需要准确抓住密封袋的拉链并拉开，同时左侧夹爪固定袋身。对于Slot Battery（插入电池），右侧夹爪需要先将电池放入遥控器的卡槽中，然后用指尖小心地将电池边缘推入直到完全插入。由于电池卡槽内的弹簧会在插入时使遥控器向反方向移动，左侧夹爪需要压住遥控器使其保持不动。对于Open Cup（打开杯盖），目标是打开一个小调味杯的盖子。由于杯子很小，夹爪无法仅从侧面接近来抓住杯身。因此我们利用两个夹爪协调：右侧手指先轻敲杯沿使其翻倒，然后将其推入左侧夹爪。左侧夹爪轻柔地合拢并将杯子抬起，随后右侧手指从下方接近并撬开杯盖。Thread Velcro（穿过魔术贴）的目标是将魔术贴扎带的一端插入另一端的小环中。Prep Tape（准备胶带）的目标是将一段短胶带挂在纸箱的边缘。Put On Shoe（穿鞋）的目标是将鞋子穿在固定的人体模型脚上，并用鞋子的魔术贴带固定。

对于仿真任务Cube Transfer（传递方块），右臂需要先拾起桌上的红色方块，然后放入另一臂的夹爪中。由于方块与左夹爪之间的间隙仅约1厘米，微小误差就可能导致碰撞。对于仿真任务Bimanual Insertion（双手插入），左右臂需要分别拾起插座和插头，然后在空中插入，间隙约5毫米。

除了精细的双手控制，我们使用的物体也给感知带来了重大挑战。例如密封袋大部分是透明的。其他透明或半透明物体包括胶带以及调味杯的杯盖和杯身。黑色桌面也与许多感兴趣的物体形成低对比度。

B. 数据收集

对于全部6个真实世界任务，我们使用ALOHA遥操作收集示范数据。每个episode人类操作者执行需要8-14秒，取决于任务复杂度，在50Hz控制频率下对应400-700个时间步。每个任务记录50条示范，Thread Velcro除外（100条）。因此每个任务的示范数据总量约为10-20分钟，由于重置和操作失误，实际耗时为30-60分钟。对于两个仿真任务，我们使用脚本策略或人类示范分别收集50条成功的示范。

C. 实验结果

我们将ACT与四种先前的模仿学习方法进行比较：BC-ConvMLP、BeT、RT-1和VINN。ACT在所有任务

上都取得了最高的成功率，大幅领先第二名算法。对于使用脚本数据或人类数据的两个仿真任务，ACT的成功率分别超过此前最佳方法59%、49%、29%和20%。对于两个真实世界任务Slide Ziploc和Slot Battery，ACT分别达到88%和96%的最终成功率，而其他方法在第一阶段之后就没有进展。我们将先前方法的糟糕表现归因于复合误差和数据中的非马尔可夫行为。

对于其余3个真实世界任务，ACT在Cup Open上达到84%成功率，Thread Velcro 20%，Prep Tape 64%，Put On Shoe 92%，均优于在这些挑战性任务上最终成功率为零的BeT。我们注意到ACT在Thread Velcro上成功率相对较低，从第一阶段的92%到最终成功的20%，每个阶段成功率约减半。我们观察到的失败模式包括：1) 在第二阶段，右臂过早闭合夹爪导致未能抓住空中的扎带尾部；2) 在第三阶段，插入不够精确错过了小环。

六、消融实验

A. 动作分块与时间集成

我们观察到成功率从 $k=1$ 时的1%急剧提升到 $k=100$ 时的44%，然后随着 k 继续增大而略微下降。这表明更多的分块和更低的有效时间跨度通常能提升性能。我们将 $k=200$ 和 $k=400$ （接近开环控制）时性能的略微下降归因于缺乏反应性行为以及建模长动作序列的困难。我们还将动作分块应用于两种基线方法，显示出与ACT一致的趋势：更多的动作分块能提升性能。

对于时间集成，BC-ConvMLP收益最大（4%的提升），其次是我们的方法（3.3%的提升）。我们注意到VINN（非参数方法）出现了性能下降，因为VINN从数据集中检索真实动作，不存在时间集成所能平滑的建模误差。

B. 使用CVAE训练

当在脚本数据上训练时，去除CVAE目标对性能几乎没有影响，因为数据集是完全确定性的。而对于人类数据，成功率从35.3%大幅下降到2%。这说明CVAE目标在从人类示范中学习时是至关重要的。

C. 高频控制是否必要？

我们进行了用户研究来说明高频遥操作对精细操作的必要性。使用相同的硬件设置，我们将频率从50Hz降低到5Hz。平均而言，参与者在5Hz下穿扎带需要33秒，而在50Hz下缩短到20秒。对于分离塑料杯，提高控制频率将任务时长从16秒降低到10秒。总体而言，将频率从50Hz降低到5Hz导致遥操作时间增加62%。我们使用"重复测量设计"统计程序正式验证了50Hz遥操作显著优于5Hz（ p 值 <0.001 ）。

七、局限性与结论

我们提出了一种用于精细操作的低成本系统，包括遥操作系统ALOHA和新颖的模仿学习算法ACT。这两部分之间的协同作用使我们能够在真实世界中直接学习精细操作技能，例如打开半透明调味杯和插入电池，成功率可达80-90%，仅需约10分钟的示范数据。

在硬件方面，ALOHA在需要双手多指协调的任务（如按压旋转打开防儿童药瓶）、需要高力量的任务（如拧开密封水瓶）以及需要指甲的任务（如开启铝制汽水罐）上仍有困难。

在策略学习方面，ACT在感知极其困难的任务上仍存在挑战，例如拆开糖果包装——撬开包装纸的接缝可能出现在糖果的任何位置。在我们的初步评估中，策略10次中有10次成功拿起糖果，10次中8次成功拉住两端，但10次中0次成功拆开包装。我们将失败归因于感知困难和数据不足。

总体而言，我们希望这一低成本开源系统能够成为推进精细机器人操作研究的重要一步和易获取的资源。